PONTIFICIA UNIVERSIDAD JAVERIANA

FACULTAD DE CIENCIAS
DEPARTAMENTO DE MATEMÁTICAS

Market Making con Aprendizaje Estadístico:

Un Enfoque Semiparamétrico para la Estimación Dinámica de Intensidades de Órdenes

Santiago Rueda

Trabajo de grado para optar al título de:
Científico de Datos

Tutor:
Vladimir Moreno

Bogotá D.C., Colombia
2026

Índice general

Resumen 1

Abstract 3

1. Introducción 4

2. Problema a Trabajar 6

3. Justificación 7

4. Objetivos 9
4.1. Objetivo General . . . 9
4.2. Objetivos Específicos . . . 9

5. Marco Teórico 10
5.1. Microestructura del libro y selección adversa . . . 10
5.2. Avellaneda–Stoikov como referencia estructural . . . 11
5.3. Procesos puntuales y modelo de Hawkes . . . 12
5.4. Intensidad semiparamétrica propuesta . . . 12
5.5. Control óptimo con inventario y la ecuación HJB . . . 14
5.6. Evaluación predictiva y valor económico . . . 15

6. Metodología 17
6.1. Variable respuesta . . . 17
6.2. Partición y protocolo . . . 17
6.3. Modelos comparados . . . 18
6.4. Evaluación predictiva . . . 19
6.5. Evaluación económica . . . 20

7. Datos: captura, reconstrucción y capa canónica 21
7.1. Captura en vivo . . . 21
7.2. Reconstrucción del libro . . . 21
7.3. Capa canónica . . . 22
7.4. Verificaciones . . . 22
7.5. Causalidad y alineación de relojes . . . 24

8. Resultados **25**
8.1. Especificación final de E3 . . . 25
8.2. P1: comparación con referencias reforzadas . . . 26
8.3. P1: test final . . . 28
8.4. P1: calibración tras barridos . . . 29
8.5. P3: política HJB con intensidades estimadas . . . 31
8.6. Valor económico en el test . . . 32
8.7. Simulación del 21 de septiembre al 26 de octubre . . . 33
8.8. Origen de la pérdida . . . 34
8.9. Avance frente a los objetivos . . . 37

9. Discusión **38**
9.1. Las dos preguntas . . . 38
9.2. Por qué la predicción no se traduce en rentabilidad . . . 39
9.3. Limitaciones . . . 40

10. Conclusiones y trabajo futuro **42**

A. Covariables y disponibilidad del código **44**
A.1. Covariables de E3 . . . 44
A.2. Disponibilidad y verificación . . . 44

B. Desarrollo y evaluación de la especificación original **46**
B.1. Fase de desarrollo . . . 46
B.2. Validación y tests ciegos . . . 46

C. Pruebas exploratorias de la parte económica **48**

Índice de tablas

6.1. Variantes comparadas. ν(hora): nivel horario; $f(\delta)$: curva monótona (5.10); S: siete señales (cinco de barrido, tendencia a 15 min y a 1 h); X49: las 49 covariables de E3 en un modelo lineal (GLM de Poisson). 19

7.1. Volumen de los datos crudos y de la capa canónica. 23
7.2. Verificaciones de la reconstrucción y de la capa canónica. 23

8.1. *Walk-forward* (cinco ventanas semanales, 34 días fuera de muestra; ajuste original). Parte de la mejora de E3 tesis sobre AS base que recupera cada modelo, ventaja de E3 tesis por intervalo [IC95 por días] y AUC a $\delta = 2$ bps. 27
8.2. Test final (4–20 sep., 17 días; modelos congelados con el ajuste corregido, idéntico al original a tres decimales). Parte de la mejora sobre AS base, ventaja de E3 tesis por intervalo [IC95 por días] y días en que gana E3 tesis (ask / bid). 29
8.3. Distancia óptima en el ask con inventario nulo (bps), mediana en el test; $\gamma = 0{,}01$, ajuste corregido. La HJB usa la curva de distancia interpolada; GLFT, una exponencial local. 31
8.4. PnL de market making en el test (17 días), bruto de comisiones; ajuste corregido. HJB con curva de distancia interpolada; GLFT con exponencial local. PnL por ejecución con IC95 por días. 32
8.5. Simulación (21 sep.–26 oct., 36 días; modelos congelados). Parte de la mejora sobre AS base, ventaja de E3 tesis por segundo [IC95 por días], días ganados y AUC (ask / bid). 34
8.6. PnL en la simulación (36 días), bruto de comisiones; modelos congelados, HJB con curva interpolada. PnL por ejecución con IC95 por días. 35
8.7. Descomposición de la pérdida por ejecución (bps; media por ejecución): distancia capturada, movimiento posterior del precio medio y *markout* a 10 s. Modelos congelados. 35
8.8. Cumplimiento de los objetivos específicos. 37

A.1. Covariables de $g(X_t)$ por grupo. 44

B.1. Fase de desarrollo. Log-verosimilitud en calibración interna (4 días, 345 600 intervalos por lado) y AUC medio ($\delta = 2$ bps). Mayor es mejor. 46
B.2. E3 original frente a E1 en bloques posteriores al desarrollo: días en que gana E3, mejora por intervalo [IC95 por días] y AUC. 46

Índice de figuras

7.1. Fracción de barridos multinivel ya reflejados en el libro s milisegundos después del evento, 29 de junio de 2026 (155 676 barridos). Otros días muestran el mismo patrón. 24

8.1. Parte de la mejora de E3 tesis sobre AS base que recupera cada modelo en el *walk-forward*. 27
8.2. Ventaja de E3 tesis sobre seis referencias en cada ventana del *walk-forward*. Todas las curvas quedan por encima de cero. 28
8.3. Parte de la mejora de E3 tesis sobre AS base que recupera cada modelo en el test final. 30
8.4. Brecha del rebote tras barridos en el *walk-forward*, por modelo y situación. Rojo: llegan más agresores del lado contrario de los que el modelo espera; azul: menos. 30
8.5. PnL bruto por ejecución (izquierda, IC95 por días) y ejecuciones por día (derecha) en el test, por intensidad y política; ajuste corregido, HJB con curva interpolada. 33

Resumen

Este trabajo estudia si la estimación de intensidades de órdenes con aprendizaje estadístico mejora el modelo clásico de *market making* de Avellaneda and Stoikov (2008), y si esa mejora tiene valor económico. El modelo clásico supone que las ejecuciones llegan como procesos de Poisson cuya intensidad decrece exponencialmente con la distancia de cotización y tiene parámetros fijos. Se propone una intensidad semiparamétrica $\lambda_i(t, \delta \mid X_t) = \exp\{g_i(X_t) + h_i(t) + m_i(X_t) f_i(\delta)\}$, en la que g_i se estima con *gradient boosting* a partir de 49 covariables causales del libro de órdenes y de las transacciones, h_i recoge la periodicidad horaria, f_i es una curva monótona de distancia y m_i modula esa curva según el estado del mercado.

La evaluación usa datos propios de BTC/USDT en Binance Spot: un libro reconstruido cada 100 ms con veinte niveles por lado y 337 millones de transacciones entre el 29 de junio y el 26 de octubre de 2026. La propuesta (E3) se compara con Avellaneda–Stoikov (E1) y con un Hawkes bivariado (E2). Por equidad, ambas referencias reciben también los hallazgos del trabajo: la curva de distancia, el efecto horario, señales de barrido y tendencia, un Hawkes de dos escalas y un modelo lineal con las mismas 49 covariables.

El documento responde dos preguntas separadas.

- **Mejora predictiva.** En una validación *walk-forward* de cinco ventanas semanales (34 días) y en la evaluación de las especificaciones finales congeladas sobre un periodo de test previamente consultado (4–20 de septiembre, 17 días), E3 supera a las referencias en ambos lados del libro, con un AUC de 0,81 en el test y de 0,85 en una simulación posterior de 36 días sin reajustes. Los intervalos de confianza por días excluyen el cero frente a todas las referencias, salvo frente a su propia variante sin covariables de barrido en el lado ask, donde la diferencia no es significativa en el test ni en la simulación. El mejor Hawkes recupera el 74 % de su mejora y el modelo lineal con las mismas covariables, el 90 %.
- **Valor económico.** Con la misma regla de ejecución para todas las intensidades, ni la política miope de Avellaneda–Stoikov ni la política obtenida resolviendo numéricamente la ecuación de Hamilton–Jacobi–Bellman, aplicada con coeficientes congelados, son rentables en el test ni en la simulación. Todas pierden aproximadamente entre 1,1 y 1,3 bps por ejecución antes de comisiones, con diferencias pequeñas entre intensidades. La única significativa

es desfavorable a E3: con la regla miope, en la simulación pierde 0,08 bps más por ejecución que los modelos que cotizan a distancia fija. Con E3, la política HJB opera menos y pierde menos por día que con Avellaneda–Stoikov y Hawkes con la misma forma de curva, pero no menos por ejecución.

La pérdida es selección adversa: en BTC/USDT el spread es de un tick ($\approx$ 0,001 bps), y lo que se captura al cotizar más lejos queda compensado por un movimiento posterior del precio mayor, de modo que cada ejecución pierde aproximadamente entre 1,1 y 1,3 bps. Predecir mejor cuándo llegan los agresores es, en este mercado, predecir también cuándo se será ejecutado antes de un movimiento en contra. La contribución es predictiva; el resultado económico es negativo en todas las configuraciones probadas.

Palabras clave: market making, control estocástico, procesos de Hawkes, modelos semiparamétricos, gradient boosting, intensidades de órdenes, selección adversa, criptoactivos.

Abstract

This thesis asks whether estimating order-arrival intensities with statistical learning improves the classical market-making model of Avellaneda and Stoikov (2008), and whether that improvement has economic value. We propose a semiparametric intensity $\lambda_i(t, \delta \mid X_t) = \exp\{g_i(X_t) + h_i(t) + m_i(X_t) f_i(\delta)\}$, where g_i is a Poisson gradient-boosting function of 49 causal order-book and trade covariates, h_i an hour-of-day effect, f_i a monotone distance curve and m_i a state-dependent modulation of that curve. Using our own reconstructed 100 ms, 20-level order book and 337 million trades of Binance Spot BTC/USDT (29 June–26 October 2026), the proposal is compared with Avellaneda–Stoikov and bivariate Hawkes benchmarks that receive every applicable improvement. In a five-window weekly walk-forward, in an evaluation of the final frozen specifications on a previously consulted test period (4–20 September) and in a later 36-day simulation without refitting, the semiparametric model beats the benchmarks on both sides of the book (test AUC 0.81, simulation AUC 0.85), with day-bootstrap intervals excluding zero except against its own variant without sweep covariables on the ask side; the best Hawkes recovers 74 % of its gain and a linear model with the same covariates 90 %. Economically, neither the myopic Avellaneda–Stoikov rule nor the numerically solved HJB policy is profitable with any intensity: all lose about 1.1–1.3 bps per fill before fees; the only significant difference is unfavourable to the semiparametric model under the myopic rule (0.08 bps per fill). The loss is adverse selection in a one-tick-spread market: better predicting when aggressors arrive is better predicting when one is filled against. The contribution is predictive; the economic result is negative in every configuration tested.

Capítulo 1

Introducción

El market making constituye uno de los problemas centrales de la microestructura de mercados modernos. Un agente que actúa como market maker provee liquidez continua al mercado publicando simultáneamente cotizaciones de compra y venta, buscando capturar la diferencia entre ambas —el spread— a cambio de asumir el riesgo de inventario y el riesgo de selección adversa (Glosten and Milgrom, 1985).

Con el auge de los mercados electrónicos y el trading algorítmico, el diseño de estrategias óptimas de market making ha adquirido una relevancia tanto académica como práctica considerable. El modelo seminal de Avellaneda and Stoikov (2008) estableció el marco de referencia: formulando el problema como uno de control estocástico en tiempo continuo, los autores derivan cotizaciones óptimas en función del inventario acumulado y la volatilidad del activo. Sin embargo, este modelo descansa sobre una especificación restrictiva: las ejecuciones se describen mediante procesos de Poisson condicionales con forma exponencial en la distancia y parámetros fijos, sin depender explícitamente de covariables contemporáneas del LOB ni de la historia reciente de eventos.

La evidencia empírica muestra las limitaciones de esta especificación. Los datos de alta frecuencia muestran que la dinámica de llegada de órdenes exhibe *clustering* temporal, dependencias entre eventos consecutivos y una fuerte sensibilidad al estado observable del libro de órdenes, fenómenos que los procesos de Poisson con parámetros fijos no pueden reproducir (Bacry et al., 2015). Esta brecha entre el modelo y la realidad puede producir intensidades mal calibradas y afectar tanto la política de cotización como el control del riesgo de inventario.

Este trabajo propone cerrar esa brecha integrando herramientas de aprendizaje estadístico dentro del marco de control estocástico, mediante un modelo semiparamétrico que estima las intensidades de órdenes como funciones del estado observable del mercado. El caso de estudio empírico se desarrolla sobre BTC/USDT en Binance Spot, un mercado de criptoactivos que opera de manera continua y sobre el cual se implementó una captura propia de datos históricos de alta frecuencia directamente desde la infraestructura pública de mercado de Binance.

El trabajo responde dos preguntas que se mantienen separadas a lo largo del

documento. La primera es predictiva: cuánto mejora la propuesta la estimación de la intensidad de llegada de órdenes agresivas a cada distancia del precio medio, frente a Avellaneda–Stoikov y a un Hawkes bivariado que reciben las mismas mejoras aplicables. La segunda es económica: qué valor produce esa mejora cuando se traduce en una política de cotización, bajo una regla de ejecución, unos costos y un inventario comunes. Una contribución predictiva puede coexistir con un resultado económico negativo, siempre que ambos se sustenten con el mismo rigor. Eso es lo que se encuentra aquí.

Las contribuciones son cuatro:

1. una especificación semiparamétrica de la intensidad que incorpora el estado del libro, la periodicidad, una curva monótona de distancia modulada por el estado y covariables de barridos;
2. una comparación con referencias reforzadas, en la que E1 y E2 reciben los mismos hallazgos que E3, evaluada con *walk-forward* y con especificaciones finales congeladas sobre un periodo de test;
3. la resolución numérica de la ecuación HJB con intensidades dependientes del estado y su evaluación económica con la misma regla de ejecución para todos los modelos;
4. una explicación cuantitativa de por qué la mejora predictiva no se traduce en rentabilidad en BTC/USDT, apoyada en tres motores de simulación y en la literatura reciente.

El Capítulo 5 presenta el marco teórico, el Capítulo 6 la metodología, el Capítulo 7 la captura y reconstrucción de los datos y el Capítulo 8 los resultados, primero los predictivos y después los económicos. El Capítulo 9 los interpreta frente a la literatura y declara las limitaciones, y el Capítulo 10 concluye.

Capítulo 2

Problema a Trabajar

Sea m_t el precio medio del activo y $X_t \in \mathbb{R}^d$ un vector de variables de mercado observables en el instante t (spread actual, desequilibrio del libro de órdenes, volatilidad realizada y volumen en ventanas causales). Se denotan por $\lambda_0^a(t \mid X_t)$ y $\lambda_0^b(t \mid X_t)$ las intensidades base de trades agresores que pueden alcanzar, respectivamente, una cotización pasiva en el ask o en el bid. La intensidad de fill a una distancia elegida δ combina esa intensidad base con una función decreciente de la distancia y una regla conservadora de ejecución reconstruida mediante replay del LOB.

El problema central de este trabajo se articula en cuatro preguntas de investigación:

P1. ¿Cómo modelar $\lambda_0^a(t \mid X_t)$ y $\lambda_0^b(t \mid X_t)$ como funciones del estado del mercado X_t y del tiempo t usando un enfoque semiparamétrico que preserve la interpretabilidad del modelo de control estocástico?

P2. ¿Qué diferencias en PnL neto y control de inventario se obtienen frente a Avellaneda–Stoikov y frente a una política basada en intensidades Hawkes?

P3. ¿Cómo impacta la estimación data-driven de las intensidades en la política óptima de cotización derivada vía la ecuación HJB?

P4. ¿El desempeño del estimador de $g(X_t)$ se mantiene fuera de muestra ante cambios de régimen, costos, latencia y especificaciones de inventario?

Capítulo 3

Justificación

La justificación de este proyecto se articula en tres dimensiones: teórica, empírica y de viabilidad.

Justificación teórica. Los modelos clásicos de market making basados en procesos de Poisson condicionales con parámetros fijos presentan limitaciones estructurales documentadas. En primer lugar, Bacry et al. (2015) revisan evidencia de fuerte endogeneidad y de dinámicas cercanas a la criticidad en diversas aplicaciones financieras de procesos de Hawkes, fenómenos que una intensidad sin memoria no puede capturar. En segundo lugar, Cont et al. (2014) documentan que el desequilibrio del flujo de órdenes explica, en promedio, alrededor del 65 % de la variación de los cambios de precio a corto plazo en su muestra de acciones, lo que confirma la relevancia del estado observable del mercado. En tercer lugar, Morariu-Patrichi and Pakkanen (2022) encuentran que la excitación y la endogeneidad del flujo de órdenes dependen fuertemente de variables de estado como el spread y el desequilibrio de colas. Estas evidencias establecen la necesidad teórica de modelos de intensidad dinámicos y sensibles al estado del mercado.

Justificación empírica. Los mercados de criptoactivos, en particular BTC/USDT en Binance, ofrecen un entorno idóneo para el desarrollo empírico de esta propuesta. Barucci et al. (2022) documentan patrones intradía en retornos, número de transacciones, volumen, volatilidad, spread y flujo de órdenes de mercados de Bitcoin, Ether y Tether, y muestran el papel central de los mercados denominados en USDT en la formación de precios. Por su parte, Fabre and Muni Toke (2025) aplican estimación Hawkes no paramétrica a la microestructura de criptomonedas. Estas evidencias motivan el uso de modelos de intensidad flexibles. La disponibilidad de infraestructura pública de mercado para BTC/USDT en Binance Spot, mediante la cual se implementó una captura propia de datos históricos de alta frecuencia, permite desarrollar una validación empírica reproducible y reduce las barreras de acceso que enfrentarían enfoques sobre mercados de renta variable tradicional.

Justificación de viabilidad. La integración propuesta de control estocástico, modelos semiparamétricos y aprendizaje estadístico es computacionalmente facti-

ble con las herramientas disponibles. Grinsztajn et al. (2022) demuestran que los métodos de Gradient Boosting y Random Forest son altamente eficientes en datos tabulares de dimensión moderada, exactamente el régimen de las covariables del estado del mercado X_t. Esto permite ciclos de estimación, validación y actualización del modelo compatibles con los recursos computacionales disponibles para la estimación y evaluación fuera de muestra.

Capítulo 4

Objetivos

4.1. Objetivo General

Desarrollar un modelo de market making que integre control estocástico, métodos semiparamétricos y machine learning para la estimación dinámica de intensidades de órdenes, evaluando su desempeño empírico sobre datos de alta frecuencia de mercados de criptoactivos.

4.2. Objetivos Específicos

OE1. Analizar el modelo de Avellaneda and Stoikov (2008) como caso base, identificando la forma exponencial en la distancia, los parámetros fijos y sus implicaciones sobre la política óptima de cotización.

OE2. Proponer un modelo semiparamétrico para las intensidades de órdenes de la forma $\lambda_0(t) = \exp\Big(g(X_t) + h(t)\Big)$, especificando el vector de covariables X_t y el componente temporal $h(t)$ a partir de propiedades documentadas de los datos de alta frecuencia.

OE3. Implementar y comparar métodos de machine learning como Gradient Boosting y Random Forest para la estimación del componente no paramétrico $g(X_t)$, usando datos L2 históricos de BTC/USDT en Binance Spot.

OE4. Derivar y resolver numéricamente la ecuación HJB bajo las intensidades semiparamétricas estimadas, obteniendo la política óptima de cotización data-driven.

OE5. Evaluar el impacto del modelo propuesto frente a Avellaneda–Stoikov y a una política basada en Hawkes mediante las métricas de PnL neto, riesgo de inventario y robustez ante cambios de régimen de mercado.

Capítulo 5

Marco Teórico

Este capítulo reúne los conceptos necesarios para formular y comparar tres enfoques de creación de mercado: el modelo de Avellaneda–Stoikov, una especificación basada en procesos de Hawkes y el modelo semiparamétrico propuesto. El hilo conductor es la intensidad con que las órdenes agresivas alcanzan una cotización pasiva a cada distancia del precio medio. En los tres casos, el creador de mercado observa el estado del libro, decide las distancias de sus cotizaciones y administra el compromiso entre capturar el spread, mantener inventario y exponerse a selección adversa.

5.1. Microestructura del libro y selección adversa

En un mercado electrónico de órdenes límite, el *limit order book* (LOB) organiza las intenciones de compra y venta por precio y prioridad temporal. En el instante t, el mejor precio comprador es b_t y el mejor vendedor es a_t; de ellos se obtienen el precio medio y el spread:

$$m_t = \frac{a_t + b_t}{2}, \qquad s_t = a_t - b_t. \tag{5.1}$$

Si $q^b_{i,t}$ y $q^a_{i,t}$ son las cantidades en el nivel i de compra y venta, dos resúmenes del estado son el desequilibrio de profundidad y el microprecio:

$$I^{(K)}_t = \frac{\sum_{i=1}^K q^b_{i,t} - \sum_{i=1}^K q^a_{i,t}}{\sum_{i=1}^K q^b_{i,t} + \sum_{i=1}^K q^a_{i,t}}, \qquad \mu_t = \frac{a_t q^b_{1,t} + b_t q^a_{1,t}}{q^b_{1,t} + q^a_{1,t}}. \tag{5.2}$$

El *order flow imbalance* (OFI) resume los cambios del mejor nivel y se relaciona con las variaciones contemporáneas del precio (Cont et al., 2014). Spread, profundidad, desequilibrio, OFI, volatilidad reciente y flujo de transacciones forman así un estado más informativo que el precio medio por sí solo.

El creador de mercado mantiene un inventario q_t, que aumenta cuando se ejecuta su compra y disminuye cuando se ejecuta su venta. El resultado de cada ejecución

pasiva se mide con su *markout*: para una venta a precio p en el instante τ,

$$\mathrm{MK}_H = \frac{p - m_{\tau+H}}{p} \times 10^4 \text{ bps}, \tag{5.3}$$

con el signo opuesto para una compra. El *markout* suma la distancia capturada respecto del precio medio y el movimiento posterior del precio. En el modelo de Glosten and Milgrom (1985), el spread compensa al creador de mercado por negociar con agentes mejor informados (O'Hara, 1995). Si el spread es mínimo, esa compensación desaparece, y el creador de mercado pierde siempre que la probabilidad de ser ejecutado esté correlacionada con un movimiento posterior desfavorable. Ese fenómeno es la *selección adversa*.

5.2. Avellaneda–Stoikov como referencia estructural

Avellaneda and Stoikov (2008) formulan la creación de mercado como un problema de control estocástico. El precio de referencia sigue $dm_t = \sigma\, dW_t$, el agente cotiza a distancias $\delta_t^b = m_t - p_t^b$ y $\delta_t^a = p_t^a - m_t$, y las ejecuciones llegan como procesos de conteo con intensidades

$$\lambda^b(\delta) = Ae^{-k\delta}, \qquad \lambda^a(\delta) = Ae^{-k\delta}. \tag{5.4}$$

A fija la escala de llegada y k la sensibilidad a alejar la orden del mercado. Con utilidad exponencial y aversión al riesgo γ, una aproximación conocida da el precio de reserva y el spread óptimo:

$$r_t = m_t - q_t\gamma\sigma^2(T-t), \qquad \psi_t = \gamma\sigma^2(T-t) + \frac{2}{\gamma}\log\!\left(1 + \frac{\gamma}{k}\right). \tag{5.5}$$

Si el inventario es positivo, el precio de reserva baja, lo que favorece vender. El modelo es interpretable, pero sus supuestos son restrictivos para alta frecuencia: A y k son fijos, las llegadas no tienen memoria y no dependen del estado del libro. En este trabajo funciona como línea base estructural: sus parámetros se estiman solo con el entrenamiento y su política se somete a la misma regla de ejecución que las demás.

5.3. Procesos puntuales y modelo de Hawkes

En un proceso de Poisson la intensidad no depende de la historia, mientras que las transacciones aparecen en ráfagas. Los procesos de Hawkes introducen autoexcitación: cada evento eleva temporalmente la probabilidad de nuevos eventos (Hawkes, 1971; Bacry et al., 2015). Para las compras agresivas (+, que alcanzan el ask) y las ventas (−, que alcanzan el bid), un Hawkes bivariado con M escalas de memoria es

$$\lambda_i(t) = \mu_i + \sum_{j\in\{+,-\}} \sum_{m=1}^{M} \alpha_{ij}^{(m)} \int_0^{t^-} \beta_m e^{-\beta_m (t-u)}\, dN_j(u), \qquad i \in \{+,-\}. \tag{5.6}$$

μ_i es la intensidad basal, $\alpha_{ij}^{(m)}$ mide el efecto de un evento de tipo j sobre el tipo i y β_m la velocidad de olvido. La estacionariedad exige que el radio espectral de la matriz de ramificación $\sum_m \alpha^{(m)}$ sea menor que uno. Con una sola escala, la estimación tiende a capturar las ráfagas de fragmentación de órdenes (milisegundos) y no la persistencia a escala de segundos; dos escalas permiten separar ambas memorias. Los parámetros se estiman con el algoritmo EM que trata como latente la estructura de ramificación (Veen and Schoenberg, 2008; Ozaki, 1979). Estos modelos se han usado para transacciones, precios y libros de órdenes (Bowsher, 2007; Lu and Abergel, 2018; Rambaldi et al., 2017; Morariu-Patrichi and Pakkanen, 2022).

Para compararlo con los demás modelos en la misma escala de tiempo, el Hawkes se evalúa con el número esperado de eventos en el intervalo siguiente, dada la historia:

$$\Lambda_i(t) = \int_0^{\Delta} \mathbb{E}\big[\lambda_i(t+u) \mid \mathcal{F}_t\big]\, du. \tag{5.7}$$

Como la esperanza condicional de los estados de excitación satisface una ecuación diferencial lineal, (5.7) tiene forma cerrada mediante la exponencial matricial.

5.4. Intensidad semiparamétrica propuesta

Sea X_t el vector de covariables causales del libro y del flujo, y $y_{t\delta}$ el número de eventos agresores del intervalo $[t, t+\Delta)$ que alcanzan $m_t(1 \pm 10^{-4}\delta)$, con δ en bps. Se modela

$$\begin{aligned} y_{t\delta} \mid X_t &\sim \text{Poisson}\Big(\Delta\, \lambda_i(t, \delta \mid X_t)\Big), \\ \lambda_i(t, \delta \mid X_t) &= \exp\Big\{g_i(X_t) + h_i(t) + m_i(X_t)\, f_i(\delta)\Big\}. \end{aligned} \tag{5.8}$$

- g_i es una función flexible del estado, estimada con *gradient boosting* (Friedman, 2001); *random forest* (Breiman, 2001) sirve de alternativa. En datos tabulares

ninguna familia domina siempre, por lo que la elección descansa en validación temporal (Grinsztajn et al., 2022).

- $h_i(t)$ recoge la periodicidad horaria con variables conocidas fuera de muestra.
- $f_i(\delta)$ es una curva monótona de distancia, con $f_i(\delta_1) = 0$ y no creciente.
- $m_i(X_t) = \exp(b_i^\top z_t)$ modula la pendiente de la curva según un vector corto de covariables estandarizadas: si $m_i > 1$, la intensidad se concentra cerca del precio medio; si $m_i < 1$, la curva se aplana.

El enlace exponencial garantiza positividad. La especificación del anteproyecto, $\exp\{g_i + h_i\}e^{-k_i\delta}$, es el caso $f_i(\delta) = -k_i\delta$ y $m_i \equiv 1$; Avellaneda–Stoikov es además el caso $g_i + h_i$ constante. La forma exponencial impone una caída a tasa constante con la distancia; empíricamente, la caída es más rápida cerca del precio medio y más lenta en la cola, y eso motiva la curva libre f_i.

Como un evento que alcanza δ_2 alcanza también toda $\delta_1 < \delta_2$, los conteos están anidados y la función

$$\ell = \sum_t \sum_\delta \Big[y_{t\delta} \log \lambda(t,\delta) - \Delta\, \lambda(t,\delta) \Big] \tag{5.9}$$

es una verosimilitud compuesta. Con $m_i \equiv 1$ y $g_i + h_i$ fijos, la condición de primer orden para cada f_j da $f_j = \log N_j - \log \sum_t \Delta e^{g_i+h_i}$. El segundo término es común a todas las distancias; la normalización $f_i(\delta_1) = 0$ lo traslada al nivel y deja la curva en forma cerrada:

$$f_j = \log \frac{N_j}{N_1}, \qquad N_j = \sum_t y_{tj}, \tag{5.10}$$

monótona porque el anidamiento hace N_j no creciente. Cuando m_i varía, f se parametriza como $f_j = -\sum_{l<j} e^{\theta_l}(\delta_{l+1} - \delta_l)$ y (θ, b) se estiman por máxima verosimilitud. Con m_i variable, $f_i(\delta_1) = 0$ deja de ser solo una normalización: como m_i multiplica a f_i, fija el punto de giro de la curva. En δ_1 la intensidad no depende de m_i, y m_i escala la caída relativa a δ_1; anclar la curva en otra distancia daría otro modelo, no una reparametrización. La escala entre f_i y m_i queda fijada porque $m_i = 1$ en el estado medio ($z_t = 0$). La estimación completa alterna los ajustes de g_i, h_i y la curva (*backfitting*), principio relacionado con la regresión semiparamétrica parcialmente lineal (Robinson, 1988; Mucciante and Sancetta, 2024).

Las covariables usan solo información disponible antes de decidir la cotización, y la respuesta corresponde al intervalo posterior; así se evita el sesgo de anticipación. Que una variable mejore la predicción no implica que modificarla cause más ejecuciones: la interpretación es predictiva, no causal.

5.5. Control óptimo con inventario y la ecuación HJB

La intensidad estimada se integra al problema de control mediante recompensas de ejecución y penalizaciones de inventario. De forma esquemática, la política maximiza

$$\mathbb{E}\left[\mathrm{PnL}_T - \phi \int_0^T q_t^2 \, dt - \eta q_T^2\right]. \tag{5.11}$$

Se consideran un precio $dS_t = \sigma \, dW_t$, cotizaciones $S_t - \delta_t^b$ y $S_t + \delta_t^a$ con intensidades $\Lambda_i(\delta) = A_i e^{-k_i \delta}$ distintas por lado, inventario $|q| \le Q$ y utilidad $-\exp\{-\gamma(X_T + q_T S_T)\}$ (Guéant et al., 2013; Guéant, 2017; Cartea et al., 2015). Con el ansatz $u = -\exp\{-\gamma(x + qS + \theta(t,q))\}$, la ecuación de Hamilton–Jacobi–Bellman se reduce a $2Q+1$ ecuaciones diferenciales:

$$0 = \partial_t \theta - \tfrac{1}{2}\gamma\sigma^2 q^2 + \mathbf{1}_{q<Q}\, H_b\Big(\theta(t,q) - \theta(t,q+1)\Big) + \mathbf{1}_{q>-Q}\, H_a\Big(\theta(t,q) - \theta(t,q-1)\Big), \tag{5.12}$$

con Hamiltoniano y distancia óptima

$$H_i(p) = \frac{A_i}{k_i + \gamma}\left(1 + \frac{\gamma}{k_i}\right)^{-k_i/\gamma} e^{-k_i p}, \qquad \delta_i^*(p) = p + \frac{1}{\gamma}\ln\left(1 + \frac{\gamma}{k_i}\right), \tag{5.13}$$

donde $p_b = \theta(q) - \theta(q+1)$ y $p_a = \theta(q) - \theta(q-1)$. Para una intensidad general $\Lambda_i(\delta)$ la reducción es la misma, con $H_i(p) = \sup_\delta \Lambda_i(\delta)\big(1 - e^{-\gamma(\delta - p)}\big)/\gamma$, que ya no tiene forma cerrada y se calcula numéricamente. El término $-\frac{1}{2}\gamma\sigma^2 q^2$ tiene la misma forma que la penalización de (5.11) con $\phi = \frac{1}{2}\gamma\sigma^2$, pero los dos objetivos no son equivalentes en general: con utilidad exponencial, el Hamiltoniano pondera la distancia por $(1 - e^{-\gamma(\delta - p)})/\gamma$, mientras que con (5.11) lo hace por $\delta - p$; ambos coinciden solo cuando $\gamma \to 0$ (Guéant, 2017). En este trabajo se usa la utilidad exponencial y el inventario final se liquida al precio medio. Para horizontes largos, $\theta(\tau, q) = c\tau + \theta_\infty(q)$ y la política estacionaria depende solo de σ^2/A_a, de A_b/A_a y de (k_a, k_b).

Guéant et al. (2013) obtienen la aproximación cerrada (GLFT) para γ pequeño:

$$\begin{aligned} \delta_b^*(q) &\approx \tfrac{1}{\gamma}\ln\Big(1 + \tfrac{\gamma}{k_b}\Big) + \Big(q + \tfrac{1}{2}\Big)\omega_b, \qquad \delta_a^*(q) \approx \tfrac{1}{\gamma}\ln\Big(1 + \tfrac{\gamma}{k_a}\Big) - \Big(q - \tfrac{1}{2}\Big)\omega_a, \\ \omega_i &= \sqrt{\tfrac{\sigma^2\gamma}{2k_i A_i}\Big(1 + \tfrac{\gamma}{k_i}\Big)^{1 + k_i/\gamma}}. \end{aligned} \tag{5.14}$$

Estas expresiones suponen que $\Lambda_i(\delta)$ es la intensidad de *ejecución* de la propia orden. Los datos permiten estimar la intensidad de *alcance* de una cotización hipotética,

que es una cota superior de la de ejecución porque no considera la posición en la cola; en este trabajo se usa como aproximación, y la evaluación económica aplica una regla de ejecución más estricta (Sección 6.5). Dos consecuencias son centrales. En GLFT la distancia base depende de k_i y no de A_i: un modelo que solo mejora el nivel de la intensidad apenas mueve las cotizaciones. En la solución numérica, en cambio, el cociente A_b/A_a entra de forma no lineal en (5.12), y la política se sesga hacia un lado incluso con inventario nulo. En el límite sin aversión ni inventario, el agente maximiza $\Lambda_i(\delta)\,\delta$ en cada instante (regla miope), cuyo óptimo exponencial es $\delta^* = 1/k_i$.

Cuando las intensidades dependen del estado, el problema exacto incluiría X_t como variable de estado. Aquí se usa la aproximación de coeficientes congelados: en cada decisión se aplica la política estacionaria con los coeficientes vigentes. En este trabajo, "política óptima" o "política HJB" designa esa política, óptima para el problema con coeficientes fijos; no es la óptima del problema que incluye la dinámica de X_t.

5.6. Evaluación predictiva y valor económico

La función (5.9) no se interpreta como la puntuación logarítmica de la distribución verdadera (Gneiting and Raftery, 2007): los conteos anidados la hacen compuesta y los datos tienen sobredispersión, así que ningún Poisson es la distribución verdadera. Su justificación es más débil y suficiente: en cada celda (t, δ), $y \log \lambda - \Delta\lambda$ es una función de puntuación estrictamente consistente para la media, cuyo valor esperado se maximiza solo cuando $\Delta\lambda = \mathbb{E}[y_{t\delta} \mid X_t]$, sea cual sea la distribución de $y_{t\delta}$ (Gneiting, 2011). La suma sobre celdas conserva la propiedad, de modo que la comparación ordena los modelos por su predicción del número esperado de eventos, no por la distribución completa. La comparación principal es, por tanto, la diferencia de (5.9) por intervalo entre dos modelos, fuera de muestra, complementada con:

- la discriminación, mediante el AUC del evento "al menos un cruce a $\delta = 2$ bps en el segundo" (Fawcett, 2006); un predictor constante obtiene 0,5;
- la calibración, mediante el cociente entre cruces observados y esperados (O/E);
- la *parte de la mejora*, $(\ell_m - \ell_{\mathrm{AS}})/(\ell_{\mathrm{E3}} - \ell_{\mathrm{AS}})$, que indica qué fracción de la ganancia de la propuesta sobre Avellaneda–Stoikov recupera cada referencia.

Los intervalos de un mismo día están correlacionados, de modo que la incertidumbre se estima con un *bootstrap* por días (Efron and Tibshirani, 1993). Para que la selección de especificaciones no contamine la evaluación, se combinan validación *walk-forward*, protocolos con los criterios escritos antes de ver resultados y una eva-

luación final con modelos congelados.

La precisión estadística no determina el valor económico (Leitch and Tanner, 1991). En market making esto tiene una forma concreta. Albers et al. (2025), con experimentos en vivo en el perpetuo de Bitcoin de Binance, encuentran una relación negativa entre la probabilidad de ejecución y el retorno posterior. DeLise (2024) describe la deriva negativa del precio tras la ejecución de una orden límite. Lalor and Swishchuk (2024) muestran que los simuladores que separan precios y llegadas sobreestiman estas estrategias. Cartea and Wang (2020) usan señales de corto plazo para reducir la selección adversa, aunque buena parte de su valor proviene de órdenes de mercado. Un modelo que ordena mejor los momentos de alta intensidad de agresores ordena también los momentos en que una cotización pasiva será ejecutada antes de un movimiento en contra. La mejora predictiva solo tendría valor económico si informara además sobre la dirección posterior, o si las comisiones compensaran la selección adversa.

Capítulo 6

Metodología

El diseño es cuantitativo, longitudinal y comparativo sobre una capa canónica del libro de órdenes y las transacciones de BTC/USDT, cuya construcción se describe en el Capítulo 7. Responde por separado dos preguntas: cuánto mejora la propuesta la predicción de la intensidad (P1) y qué valor económico produce en una política de cotización (P2–P3).

6.1. Variable respuesta

La respuesta se define sobre *eventos agresores*: transacciones con el mismo instante y el mismo lado, que corresponden a una orden agresiva que barre uno o varios niveles, con su precio extremo. Para cada segundo $[t, t+1)$ y cada distancia $\delta \in \{0{,}5; 1; 2; 3; 5; 7{,}5; 10; 15; 20\}$ bps se cuentan los eventos compradores que alcanzan $m_t(1 + 10^{-4}\delta)$ (lado ask) y los vendedores que alcanzan $m_t(1 - 10^{-4}\delta)$ (lado bid). Un segundo es válido solo si el libro es observable en todas sus filas. Que el precio alcance una cotización hipotética no implica que una orden pasiva se ejecute: la respuesta mide la intensidad de *alcance*, que no depende de la posición en la cola y se utiliza como proxy de la intensidad de ejecución.

6.2. Partición y protocolo

Bloque	Fechas (2026)	Uso
Entrenamiento	29 jun.–3 sep. (67 días)	Desarrollo, *walk-forward* y ajuste de los modelos finales
Test	4–20 sep. (17 días)	Evaluación de los modelos finales congelados, predictiva y económica
Simulación	21 sep.–26 oct. (36 días)	Evaluación única de los mismos modelos y políticas, sin ningún reajuste

Dentro del entrenamiento se desarrolló la especificación de E3 (covariables, hiperparámetros, curva de distancia) y se reforzaron las referencias. Después, el orden

fue fijo:

1. *walk-forward* con cinco ventanas semanales expansivas: se ajusta desde el 29 de junio hasta el 31 de julio, 7, 14, 21 y 28 de agosto, y se evalúa en los siete días siguientes (34 días fuera de muestra);
2. ajuste de los modelos finales con todo el entrenamiento, que se guardan sin cambios posteriores;
3. evaluación del test;
4. simulación, una sola vez, con los modelos y las políticas congelados.

Cada paso tuvo un protocolo con sus criterios escritos antes de correr. Antes de abrir la simulación se comprobó que su código reproduce exactamente un día del test.

Versiones de los modelos. Los resultados provienen de dos versiones del ajuste, que se identifican en cada tabla:

- **ajuste original**: el *walk-forward* y los modelos finales con los que se evaluó primero el test;
- **ajuste corregido**: una revisión posterior encontró que el último paso de la curva de E3 no verificaba la convergencia y que su gradiente omitía el recorte de $m(X)$. Se corrigió y se reestimó solo ese paso (la curva, su modulación y un ajuste de nivel) para E3 tesis y E3-fkX, con g y h fijos y convergencia comprobada de ese paso, sin tocar las demás variantes. El test predictivo repetido con el ajuste corregido coincide con el original a tres decimales en todas las métricas.

El *walk-forward* se conserva con el ajuste original; la evaluación económica usa el ajuste corregido. Ningún parámetro ni hiperparámetro se estimó con el periodo de test. El periodo se evaluó más de una vez: las versiones posteriores corrigieron defectos del código señalados en revisiones, no se eligieron por su desempeño en el test y no cambiaron las conclusiones. El test no es ciego en sentido estricto, porque la versión original de E3 se había evaluado en esas fechas (Apéndice B); lo que confirma son las especificaciones finales, que nunca se evaluaron allí.

6.3. Modelos comparados

Para que la comparación no favorezca a la propuesta, cada mejora aplicable a las referencias se les dio también: la curva de distancia, el nivel horario, un Hawkes de dos escalas, siete señales de barrido y tendencia, y un modelo lineal con las mismas covariables de E3. La Tabla 6.1 resume las once variantes; todas comparten respuesta, distancias, segundos y datos, y se ajustan por lado.

Tabla 6.1: Variantes comparadas. ν(hora): nivel horario; $f(\delta)$: curva monótona (5.10); S: siete señales (cinco de barrido, tendencia a 15 min y a 1 h); X49: las 49 covariables de E3 en un modelo lineal (GLM de Poisson).

Variante	$\log \lambda_i(t, \delta)$
AS base	$a_i - k_i\delta$
AS + h + f	$\nu_i(\text{hora}) + f_i(\delta)$
AS + S	$\nu_i(\text{hora}) + \beta_i^\top S_t + f_i(\delta)$
GLM lineal	$\nu_i(\text{hora}) + \beta_i^\top X_t + f_i(\delta)$, 49 covariables
Hawkes 1 esc. + h + f / + S	$\log \Lambda_i(t) + \ldots$, Hawkes de una escala (5.7)
Hawkes 2 esc. + h + f / + S	$\log \Lambda_i(t) + \ldots$, Hawkes de dos escalas (5.6)
E3 base	$g_i(X_t) + h_i(t) - k_i\delta$, 44 covariables
E3-fkX	$g_i(X_t) + h_i(t) + m_i(X_t) f_i(\delta)$, 44 covariables
E3 tesis	(5.8) con 49 covariables (44 + 5 de barrido)

g_i es un *HistGradientBoosting* con pérdida Poisson (tasa de aprendizaje 0,05; 15 hojas; al menos 2 000 observaciones por hoja; 300 iteraciones; regularización L2 de 1) (Pedregosa et al., 2011), con tres ciclos de *backfitting*. En cada ciclo: (i) con la curva y h fijas, se ajusta g por Poisson sobre el total de eventos del segundo, usando como desplazamiento la suma de la curva sobre las distancias; (ii) se reestima h como nivel por hora; (iii) con $g + h$ fijos, se estiman la curva f y los coeficientes b de $m(X)$ por máxima verosimilitud (L-BFGS con gradiente analítico). La identificación se obtiene fijando $f(\delta_1) = 0$ (que además fija el punto de giro de la modulación; Sección 5.4), centrando h sobre las 24 horas y absorbiendo el nivel común en una constante. El número de ciclos es fijo; se verificó que la verosimilitud de entrenamiento aumenta en cada ciclo, sin un criterio formal de convergencia. Los Hawkes se estiman con un tercio de los días de cada ventana, por costo computacional; sus capas de nivel, forma y señales usan todos los días. La lista de covariables está en el Apéndice A.

6.4. Evaluación predictiva

Se compara la log-verosimilitud (5.9) por segundo, el AUC a $\delta = 2$ bps (promedio de los AUC diarios) y la calibración tras barridos (Sección 5.6), con intervalos *bootstrap* por días (2 000 réplicas). Los criterios del *walk-forward* son que E3 tesis supere a cada referencia en las cinco ventanas y con intervalo de confianza positivo. Los del test son cuatro: superar a las referencias principales con intervalo positivo, ganar al menos 14 de 17 días al mejor Hawkes, un AUC de al menos 0,80 y un error de calibración tras barridos de a lo sumo 0,15.

6.5. Evaluación económica

Todas las intensidades se evalúan en el test con el mismo simulador:

- cada segundo y en cada lado se cotiza una orden de 0,01 BTC a la distancia que indica la política, redondeada al tick y siempre pasiva;
- la orden se ejecuta solo si, dentro de ese segundo, un agresor negocia a un precio *estrictamente* más allá del suyo (regla de cruce estricto). La regla no modela la cola: omite las ejecuciones al mismo precio de la orden, por lo que tiende a contar menos ejecuciones, pero no garantiza que el PnL resultante sea conservador;
- la decisión usa el estado de la capa al inicio del segundo y la orden queda activa desde ese instante, sin latencia de envío; la sensibilidad a la latencia se estudió por separado en el entrenamiento (Sección 8.8);
- el inventario se limita a $|q| \leq 10$ y se valora al último precio medio del día.

Se evalúan tres políticas: la regla miope $\delta^* = \arg\max_\delta \lambda(\delta)\,\delta$; la política HJB numérica (Sección 5.5) con $\gamma = 0{,}01$, elegido en la fase de desarrollo con la versión original de los modelos, y $Q = 10$; y su aproximación GLFT. Para la HJB, la intensidad de cada modelo se usa con su curva de distancia interpolada entre los nueve nodos (Sección 8.5); GLFT, cuya forma cerrada solo existe para intensidades exponenciales, usa en cada segundo un ajuste exponencial en $\delta \leq 5$ bps. La volatilidad es una media móvil exponencial causal, común a todos, con vida media de 60 s. Unidades: distancias y precios en bps del precio medio, tiempo en segundos, A_i en eventos por segundo, k_i en bps^{-1}, σ en $\text{bps}/\sqrt{\text{s}}$, inventario q en órdenes de 0,01 BTC y γ en bps^{-1} por orden.

Se reportan el PnL por ejecución y por día antes de comisiones, los días positivos, el número de ejecuciones, el inventario medio y el *markout* a 10 s. El PnL de un día es el efectivo final más el inventario valorado al último precio medio, en USDT. El PnL por ejecución en bps es $10^4\times$ la suma del PnL de los días dividida por la suma del valor negociado (precio de cada ejecución por 0,01 BTC); su intervalo de confianza se obtiene remuestreando días.

Capítulo 7

Datos: captura, reconstrucción y capa canónica

Los datos de este trabajo no provienen de un proveedor comercial: se capturaron en vivo desde la infraestructura pública de Binance y se reconstruyó con ellos el libro de órdenes completo de BTC/USDT en Binance Spot. Este capítulo describe cómo se hizo y cómo se verificó.

7.1. Captura en vivo

Un servidor dedicado en Alemania se conectó de forma continua a dos flujos públicos de Binance Spot para BTC/USDT: el flujo de profundidad, que publica cada 100 ms los cambios del libro, y el flujo de transacciones, que publica cada operación con su precio, cantidad, lado agresor y hora del motor de negociación. Cada flujo se capturó dos veces en paralelo (captura primaria y de respaldo), de modo que un mensaje perdido por una conexión pudiera recuperarse de la otra. Los archivos se rotaron cada 12 horas y cada mensaje se guardó sin modificar, junto con su hora de recepción local. Periódicamente se descargaron instantáneas completas del libro, que sirven de punto de partida para la reconstrucción.

Las horas registradas permiten medir los retrasos. Binance publica cada transacción alrededor de 1 ms después de ejecutarla. La red añade una mediana de 127–131 ms hasta el servidor (percentiles 5 y 95 de unos 120 y 145 ms). Los mensajes de profundidad llegan en lotes regulares cada 100 ms, sin hora propia para cada cambio dentro del lote.

7.2. Reconstrucción del libro

El libro se reconstruyó siguiendo el procedimiento oficial de Binance para mantener un libro local (Binance, 2026):

1. se parte de una instantánea completa del libro;

2. se aplican los mensajes de profundidad en orden, verificando que sus números de secuencia sean consecutivos;
3. las capturas primaria y de respaldo se combinan por número de secuencia, sin duplicar mensajes;
4. si falta un tramo de secuencia que ninguna captura cubre, el libro se marca como inválido hasta la siguiente instantánea, y ese intervalo nunca se interpola.

Las transacciones se contrastaron con el archivo histórico oficial de Binance, que tiene la hora del motor con resolución de microsegundos; ese archivo se usó para verificar y completar transacciones, nunca para fabricar cambios del libro.

7.3. Capa canónica

A partir del libro reconstruido y de las transacciones se construyó una capa de estado cada 100 ms para el periodo del 29 de junio al 26 de octubre de 2026: 120 días, 864 000 filas por día y 202 columnas. Cada fila contiene los veinte mejores niveles de cada lado, indicadores de validez y variables causales del libro, del flujo de transacciones y de la volatilidad, calculadas solo con información anterior a la fila. Las 337 millones de transacciones del periodo se conservan por separado, una por una. Toda la capa se construyó con el mismo código, y cada archivo queda registrado en un catálogo que permite verificar su integridad.

La Tabla 7.1 resume el volumen de datos. El inventario del servidor al 19 de octubre registra 85 GB comprimidos capturados desde el 29 de junio (113 días): 64 GB de libros, 19 GB de transacciones y 2 GB del archivo oficial de Binance. Esa cifra incluye una captura paralela de Coinbase (BTC/USD), que se usó solo en la fase exploratoria. La parte de Binance BTC/USDT, con primaria y respaldo, suma unos 40 GB en esos 113 días. Coincide con lo medido en dos días completos conservados (27 y 28 de julio), que extrapolado a los 120 días da unos 42 GB comprimidos y 430 GB sin comprimir. Cada captura recibió unos 862 800 mensajes de profundidad al día, de 864 000 posibles (99,9 %), y las dos capturas difieren en pocos cientos de mensajes por día. Unos 880 millones de mensajes crudos se convierten así en una capa de 38 GB lista para modelar.

7.4. Verificaciones

La Tabla 7.2 resume las verificaciones.

Los 13 tramos que no coinciden contienen huecos de secuencia; quedaron marcados como inválidos y no se usaron. Las pequeñas diferencias de profundidad frente

Tabla 7.1: Volumen de los datos crudos y de la capa canónica.

	Mensajes o filas	Comprimido	Sin comprimir
Servidor, todo (medido, 113 días)	—	85 GB	—
Binance, primaria (120 días)	≈440 millones	≈21 GB	≈214 GB
Binance, ambas capturas (120 días)	≈880 millones	≈42 GB	≈430 GB
Canónica: libro (202 columnas)	104 millones de filas	35 GB	—
Canónica: transacciones	337 millones	3 GB	—

Tabla 7.2: Verificaciones de la reconstrucción y de la capa canónica.

Verificación	Resultado
Tramos entre instantáneas cuyo libro reconstruido coincide exactamente con la instantánea siguiente (100 niveles por lado)	103 de 116
Instantáneas posteriores con fila correspondiente que coinciden exactamente en 20 niveles	18 de 18
Conflictos de precio o cantidad entre transacciones capturadas y el archivo oficial	0
Mejores precios distintos frente a una reconstrucción independiente (22,9 millones de filas comparadas)	2 por lado
Libros cruzados, niveles desordenados o cantidades no positivas	0
Fracción mínima de filas válidas en un día	99,95 %
Tiempo con spread de un tick (0,01 USDT), entrenamiento	99,96 %

a la reconstrucción independiente (0,01–0,04 % de las filas) se concentran en niveles alejados del mejor precio.

7.5. Causalidad y alineación de relojes

Las covariables deben usar solo información anterior a cada decisión. Para comprobar que la capa no contiene información del intervalo que se quiere predecir se midió, para cada transacción agresiva que barre varios niveles, la fracción de casos en que el libro vigente s milisegundos después del evento ya refleja el barrido. Si hubiera fuga, el barrido aparecería en $s \leq 0$. La fracción se mantiene en el nivel de fondo (cerca de 1 %) hasta $s = 80$ ms, sube desde $s \approx 90$ ms y se completa hacia $s \approx 200$ ms (Figura 7.1).

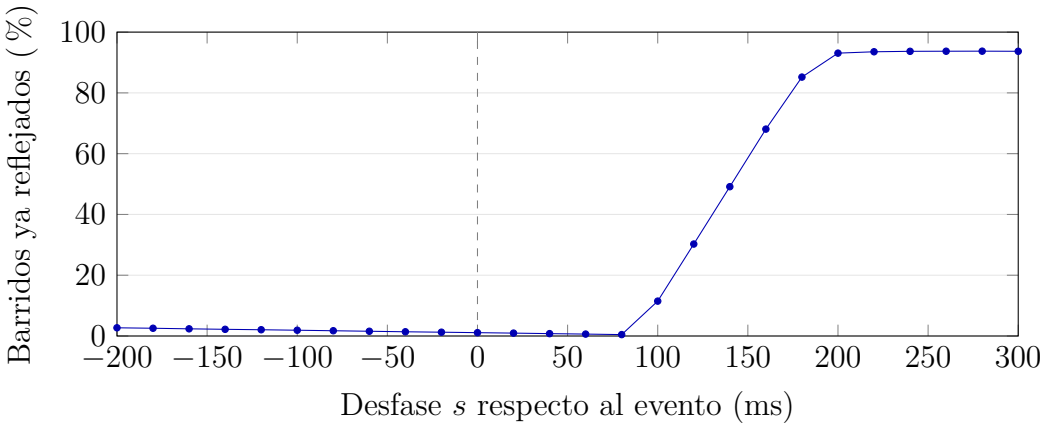


Figura 7.1: Fracción de barridos multinivel ya reflejados en el libro s milisegundos después del evento, 29 de junio de 2026 (155 676 barridos). Otros días muestran el mismo patrón.

No hay fuga detectable: el libro va unos 90 ms detrás del reloj de las transacciones, por la publicación en lotes de 100 ms. Un participante real vería además el estado con el retraso de red. Por eso se verificó, con la versión original de E3, que un retraso adicional de 200 ms en las covariables conserva entre el 81 y el 90 % de su ventaja predictiva.

Capítulo 8

Resultados

El capítulo sigue el orden de las preguntas. La Sección 8.1 resume cómo se llegó a la especificación final de E3; es la única parte exploratoria del capítulo. Las Secciones 8.2 a 8.4 responden P1 (mejora predictiva), la Sección 8.5 responde P3 (efecto sobre la política), las Secciones 8.6 y 8.8 responden P2 (valor económico), y la Sección 8.7 repite ambas evaluaciones en un periodo posterior. Las diferencias de log-verosimilitud se expresan por segundo, sumando las nueve distancias; un valor positivo favorece a E3 tesis.

8.1. Especificación final de E3

La especificación se desarrolló dentro del entrenamiento, comparando siempre fuera de muestra por días. Cuatro resultados la definieron.

El estado del mercado explica la mayor parte de la intensidad. La versión del anteproyecto, $\exp\{g(X) + h(t)\}e^{-k\delta}$ con 44 covariables, redujo a la mitad la log-verosimilitud negativa de Avellaneda–Stoikov en la fase de desarrollo y alcanzó un AUC de 0,84, frente a 0,50 de AS y 0,64–0,65 del Hawkes de una escala. En ablaciones por grupos, el flujo reciente de transacciones fue el más informativo, seguido del libro y de la volatilidad; el OFI resultó casi redundante. El componente horario mejora el lado ask pero no el bid, y se usa solo en el ask. Evaluada después sin reajustar, esa versión superó a AS todos los días de una validación y de dos tests ciegos, aunque uno de los tres veredictos preregistrados no se cumplió (Apéndice B).

Gradient boosting frente a random forest (OE3). Con la misma información, ambos estimadores de g llegan a la misma conclusión: la log-verosimilitud difiere en menos del 1,2 % y el AUC en una milésima, en desarrollo y en validación. *Random forest* cuesta entre 4 y 35 veces más tiempo de cómputo, por lo que *gradient boosting* es el estimador principal.

La forma exponencial en la distancia estaba mal calibrada. A 2 bps, la versión original predecía entre 1,6 y 1,9 veces los cruces observados. Reemplazar $-k\delta$ por la curva monótona (5.10) reduce el mayor desvío de $\log(O/E)$ entre distancias de 5,6 a 0,4 en el ask y de 8,1 a 2,3 en el bid, con una mejora de +0,031 y +0,032 por segundo en todos los días, sin cambio en el AUC. Modular la curva por el estado, $m(X)f(\delta)$, añade +0,011 a +0,016. La curva final cae a $f(2) = -1{,}64$ y $f(20) = -8{,}65$ en el ask ($-1{,}68$ y $-10{,}31$ en el bid): más rápido cerca del precio medio y más lento en la cola.

Faltaban covariables de barrido. Tras un barrido comprador, el cociente estimado λ_a/λ_b a 2 bps pasa de 1,3 a 5,6, de modo que E3 capta el impulso del barrido. Pero subestimaba el rebote del lado contrario: tras barridos vendedores llegaban cerca de un 60 % más compradores de los esperados. Cinco covariables causales (recorrido firmado, volumen y tiempo desde el último barrido; spread máximo y variación del precio medio en el último segundo) reducen esa brecha de 0,454 a 0,091.

La especificación final, **E3 tesis**, es (5.8) con 49 covariables, h horaria en el ask, curva f monótona y $m(X) = \exp(b^\top z)$ con cuatro covariables. Sus coeficientes de modulación son pequeños ($|b_j| \leq 0{,}10$).

8.2. P1: comparación con referencias reforzadas

Las referencias reciben las mismas mejoras aplicables que E3 (Tabla 6.1). El Hawkes de dos escalas ajustado con todo el entrenamiento elige memorias de 1 s y 3,3 ms ($\beta = 1$ y 300 s^{-1}) con radio espectral 0,74; el de una escala elige solo la escala rápida.

La Tabla 8.1 y la Figura 8.1 resumen los 34 días fuera de muestra del *walk-forward*. La ventana 1 reproduce exactamente los resultados obtenidos antes con el mismo ajuste (diferencia relativa nula), lo que verifica el código.

Se cumplen los dos criterios principales del protocolo. *Estabilidad*: E3 tesis supera a cada uno de los diez modelos en las cinco ventanas y en ambos lados (Figura 8.2). *Diferencia global*: el intervalo de confianza de la ventaja es positivo frente a todos; frente a E3-fkX gana 25 y 23 de 34 días, y frente a los demás, 33 o 34 de 34. La ventaja crece en las semanas agitadas (15–28 de agosto), en las que una intensidad constante falla más.

El diagnóstico de sobreajuste compara la ventaja de E3 sobre el GLM lineal en la semana siguiente con la de la última semana ajustada. El cociente está por debajo

Tabla 8.1: *Walk-forward* (cinco ventanas semanales, 34 días fuera de muestra; ajuste original). Parte de la mejora de E3 tesis sobre AS base que recupera cada modelo, ventaja de E3 tesis por intervalo [IC95 por días] y AUC a $\delta = 2$ bps.

	Parte de la mejora		E3 tesis − modelo		AUC	
Modelo	ask	bid	ask	bid	ask	bid
E3 tesis	100 %	100 %	–	–	0,834	0,825
E3-fkX (44 cov.)	98,6 %	99,5 %	+0,024 [0,005; 0,050]	+0,008 [0,002; 0,015]	0,833	0,824
E3 base	92,7 %	93,5 %	+0,127 [0,058; 0,225]	+0,110 [0,045; 0,213]	0,834	0,824
GLM lineal (49 cov.)	90,9 %	90,1 %	+0,158 [0,111; 0,223]	+0,166 [0,102; 0,254]	0,821	0,814
Hawkes 2 esc. + S	79,1 %	75,8 %	+0,365 [0,275; 0,470]	+0,408 [0,286; 0,554]	0,780	0,772
Hawkes 2 esc. + h + f	61,7 %	60,9 %	+0,668 [0,442; 0,962]	+0,659 [0,424; 0,959]	0,757	0,752
Hawkes 1 esc. + S	52,4 %	49,0 %	+0,830 [0,593; 1,114]	+0,860 [0,565; 1,206]	0,731	0,725
AS + S	50,8 %	47,0 %	+0,857 [0,609; 1,152]	+0,893 [0,582; 1,261]	0,728	0,721
Hawkes 1 esc. + h + f	9,2 %	9,1 %	+1,582 [0,995; 2,303]	+1,530 [0,941; 2,240]	0,628	0,626
AS + h + f	7,4 %	6,9 %	+1,614 [1,012; 2,352]	+1,567 [0,961; 2,294]	0,616	0,612
AS base	0 %	0 %	+1,743 [1,122; 2,483]	+1,684 [1,061; 2,440]	0,500	0,500

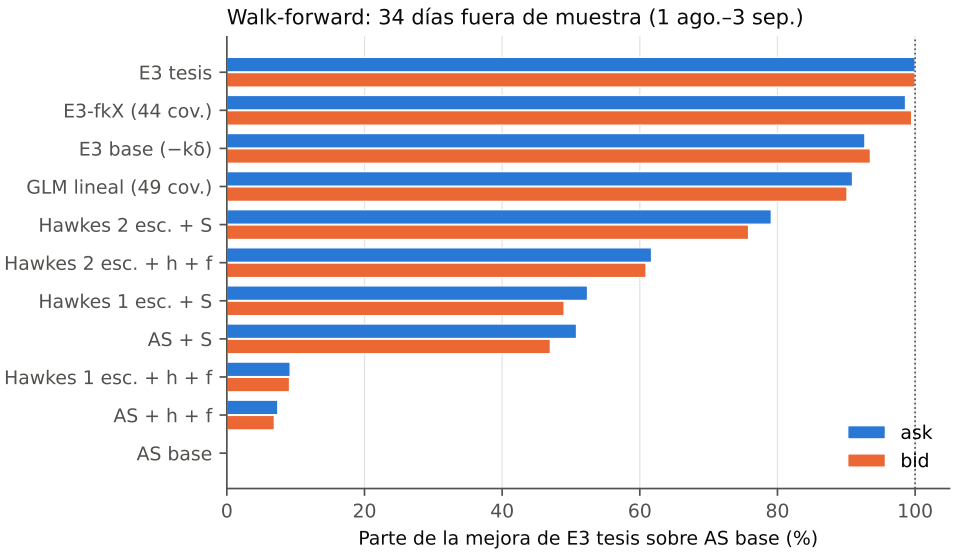


Figura 8.1: Parte de la mejora de E3 tesis sobre AS base que recupera cada modelo en el *walk-forward*.

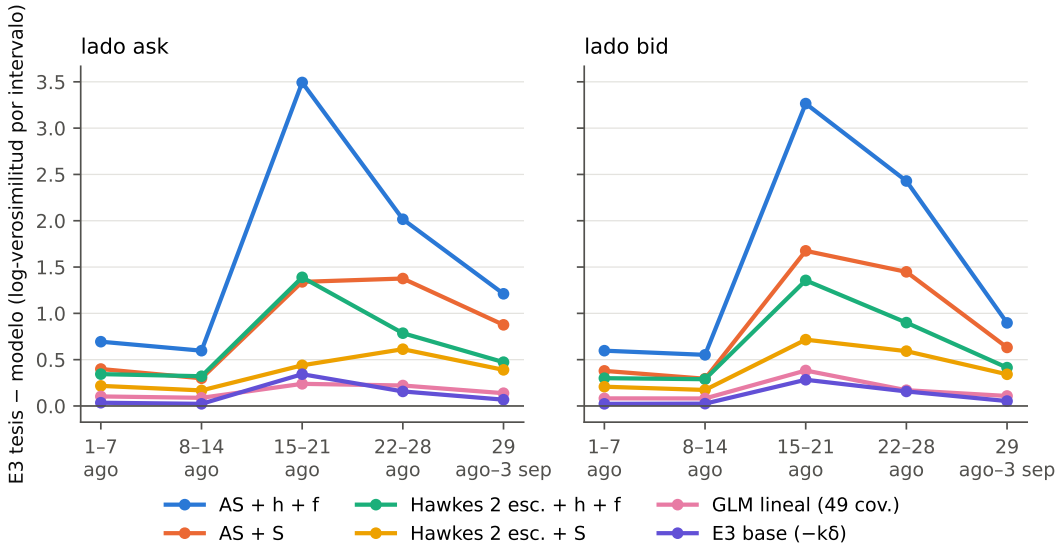


Figura 8.2: Ventaja de E3 tesis sobre seis referencias en cada ventana del *walk-forward*. Todas las curvas quedan por encima de cero.

de 0,5 en dos de cinco ventanas (V4 y V5), en las que la semana ajustada incluye el periodo agitado del 15 al 28 de agosto y la ventaja dentro de muestra se infla; el umbral del protocolo (tres ventanas) no se alcanza. En la ventana 3 el cociente supera 2, porque la semana evaluada es la agitada.

Tres lecturas se desprenden de la Tabla 8.1. Primera, el estado del libro explica la mayor parte de la mejora: el GLM lineal con las mismas covariables recupera el 90–91 %. La no linealidad de g aporta el resto, mejora la discriminación (AUC 0,834 frente a 0,821) y, entre los modelos evaluados, es la que mejor corrige el rebote (Sección 8.4). Segunda, la memoria importa, pero con la escala correcta: el Hawkes de dos escalas recupera el 61–62 % frente al 9 % del de una escala. Tercera, las variables de barrido aportan poco a la verosimilitud global (E3-fkX recupera el 98,6–99,5 %), porque los barridos son eventos raros; su valor está en la calibración tras esos eventos.

8.3. P1: test final

Con los once modelos ajustados en todo el entrenamiento y congelados antes de leer el test, se evaluaron en el test del 4 al 20 de septiembre. El periodo ya se había consultado con la versión original de E3, y las especificaciones finales se evaluaron en él más de una vez, por correcciones de código que no se eligieron por su desempeño ni cambiaron las conclusiones (Sección 6.2). Se cumplen los cuatro criterios preregistrados (Tabla 8.2):

- **jerarquía**: E3 tesis supera a AS + h + f, AS + S, GLM lineal, Hawkes 2 escalas + h + f y Hawkes 2 escalas + S con IC95 positivo en ambos lados;
- **consistencia**: gana 17 de 17 días al Hawkes de dos escalas con señales en ambos lados;
- **discriminación**: AUC de 0,813 en ambos lados, por encima de 0,80;
- **rebote**: brecha de +0,116 tras barridos vendedores y −0,139 tras compradores, dentro de ±0,15.

Tabla 8.2: Test final (4–20 sep., 17 días; modelos congelados con el ajuste corregido, idéntico al original a tres decimales). Parte de la mejora sobre AS base, ventaja de E3 tesis por intervalo [IC95 por días] y días en que gana E3 tesis (ask / bid).

	Parte de la mejora		E3 tesis − modelo		
Modelo	ask	bid	ask	bid	Días
E3-fkX (44 cov.)	99,8 %	98,9 %	+0,002 [−0,004; 0,008]	+0,015 [0,003; 0,029]	10 / 13
E3 base	96,0 %	93,5 %	+0,053 [0,034; 0,073]	+0,087 [0,047; 0,134]	16 / 17
GLM lineal (49 cov.)	91,6 %	89,6 %	+0,110 [0,077; 0,145]	+0,140 [0,089; 0,193]	16 / 16
Hawkes 2 esc. + S	73,8 %	73,7 %	+0,345 [0,251; 0,454]	+0,353 [0,263; 0,457]	17 / 17
Hawkes 2 esc. + h + f	60,3 %	62,3 %	+0,523 [0,377; 0,692]	+0,505 [0,355; 0,681]	17 / 17
Hawkes 1 esc. + S	45,1 %	44,6 %	+0,723 [0,494; 0,985]	+0,742 [0,510; 1,007]	17 / 17
AS + S	43,6 %	43,0 %	+0,742 [0,508; 1,010]	+0,764 [0,526; 1,036]	17 / 17
Hawkes 1 esc. + h + f	11,1 %	12,3 %	+1,170 [0,775; 1,644]	+1,175 [0,743; 1,678]	17 / 17
AS + h + f	9,5 %	10,4 %	+1,191 [0,788; 1,671]	+1,200 [0,759; 1,714]	17 / 17
AS base	0 %	0 %	+1,316 [0,880; 1,810]	+1,340 [0,835; 1,953]	17 / 17

El orden de los modelos es el mismo que en el *walk-forward* (Figura 8.3) y el AUC baja de 0,83 a 0,81, una degradación moderada en datos nuevos. Frente a E3-fkX, la ventaja en el lado ask no es significativa: las variables de barrido no mejoran la predicción global en ese lado, aunque sí la calibración del rebote. Los AUC de las referencias en el test son 0,80 (GLM), 0,76–0,77 (Hawkes 2 escalas + S), 0,74–0,75 (Hawkes 2 escalas + h + f), 0,71–0,72 (AS + S), 0,61–0,63 (AS y Hawkes 1 escala con h y f) y 0,50 (AS base).

8.4. P1: calibración tras barridos

La Figura 8.4 muestra, para el *walk-forward*, la brecha entre la razón O/E del lado contrario tras barridos y la razón O/E habitual, separada por el lado del barrido y por la tendencia de la última hora. Cero indica que el modelo acierta tras un barrido tan bien como en momentos normales.

Los modelos sin covariables de estado (AS y Hawkes con h y f) subestiman fuertemente el rebote, con brechas de +0,6 a +2,7. Las señales lineales lo sobrecorrigen en la celda “comprador con tendencia bajista” (−0,4 a −0,5). E3 tesis tiene las brechas

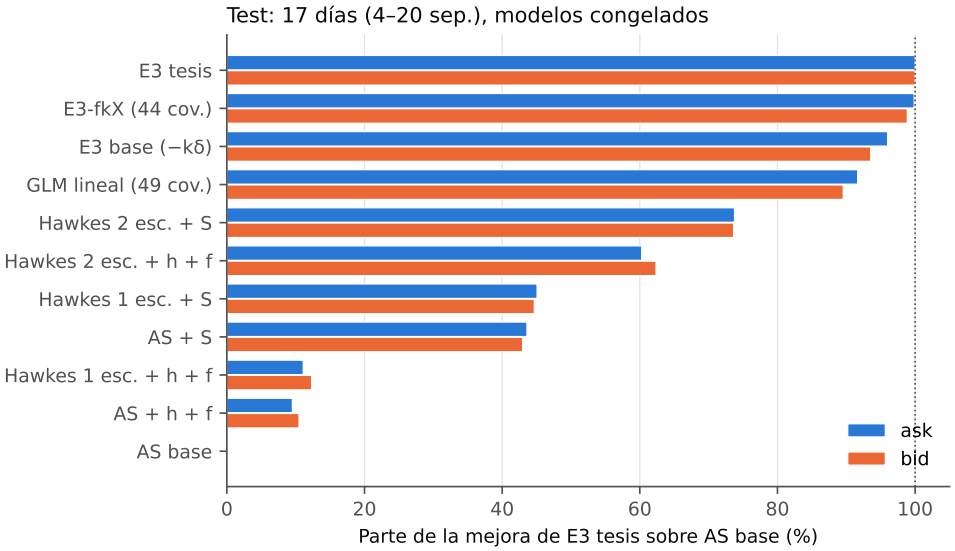


Figura 8.3: Parte de la mejora de E3 tesis sobre AS base que recupera cada modelo en el test final.

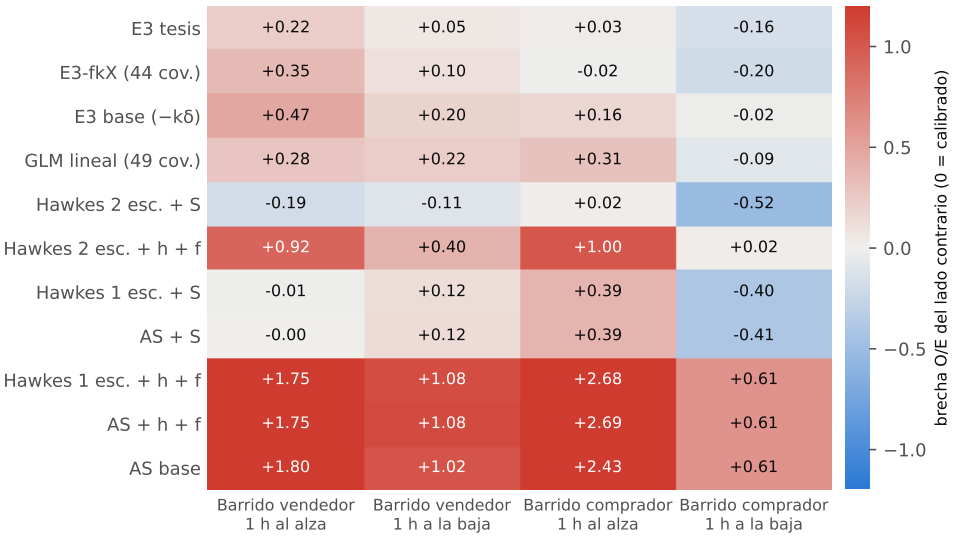


Figura 8.4: Brecha del rebote tras barridos en el *walk-forward*, por modelo y situación. Rojo: llegan más agresores del lado contrario de los que el modelo espera; azul: menos.

más cercanas a cero en tres de las cuatro celdas. La celda "comprador con tendencia bajista" (−0,16) no la corrige ningún modelo y queda como limitación declarada. En el test, la celda más débil de E3 tesis es "comprador con tendencia alcista" (−0,235).

8.5. P3: política HJB con intensidades estimadas

La HJB (5.12) se resolvió numéricamente con un esquema de Euler implícito linealizado, incondicionalmente estable porque la matriz del sistema es una M-matriz, seguido de un paso de Newton sobre el régimen ergódico. El Hamiltoniano se calcula con la curva de distancia de cada modelo interpolada: $\log \Lambda_i(\delta)$ es lineal a trozos entre los nueve nodos de δ y se extiende con la pendiente del primer y del último tramo; en cada tramo el máximo de $\Lambda_i(\delta)(1 - e^{-\gamma(\delta - p)})/\gamma$ tiene forma cerrada, y H_i es el máximo sobre los tramos, con δ restringida a $[-5; 40]$ bps. Para aplicarla cada segundo se precalculan tablas en $(\ln \sigma^2/A_a, \ln A_b/A_a)$ y, para E3 tesis y E3-fkX, también en (m_a, m_b), con rangos tomados de seis días de entrenamiento. Antes de usarla en el test se verificó en el entrenamiento que:

- con forma exponencial reproduce la solución de la Sección 5.5 (diferencia máxima 10^{-14}), que a su vez reproduce la solución lineal de Guéant (2017);
- el máximo por tramos coincide con una búsqueda exhaustiva en una rejilla fina (error relativo máximo 2×10^{-8});
- las distancias son monótonas en el inventario;
- las tablas reproducen la solución exacta con un error p99 de a lo sumo 0,027 bps en todo $|q| \leq 10$.

Ninguna pendiente de tramo resultó menor que 0,16 bps^{-1} y ninguna distancia óptima tocó los bordes del intervalo. La aversión $\gamma = 0{,}01$ se eligió en la fase de desarrollo. La Tabla 8.3 muestra cómo cambia la política con cada intensidad.

Tabla 8.3: Distancia óptima en el ask con inventario nulo (bps), mediana en el test; $\gamma = 0{,}01$, ajuste corregido. La HJB usa la curva de distancia interpolada; GLFT, una exponencial local.

Intensidad	HJB	GLFT
AS base (forma exponencial)	1,55	1,49
E3 base (forma exponencial)	1,50	1,51
AS, Hawkes y GLM con curva $f(\delta)$	1,11–1,14	1,48–1,49
E3 tesis	0,85	1,25

Tres resultados responden a P3. Primero, en GLFT la distancia base no depende del nivel A, de modo que las referencias apenas mueven las cotizaciones respecto de AS. Segundo, la forma de la curva sí importa en la solución numérica: con la

curva interpolada, los modelos con $f(\delta)$ cotizan unos 0,4 bps más cerca que con una exponencial, y E3 tesis, cuya pendiente cerca del precio medio depende del estado, unos 0,7 bps más cerca. Frente a la versión que aproxima cada intensidad por una exponencial local, el precio cotizado cambia en el 86–99 % de las decisiones de esos modelos. Tercero, el cociente A_b/A_a que predice E3 sesga la política hacia un lado incluso con inventario nulo. Los valores negativos de la distancia, que cruzarían el precio medio, se acotan al mejor precio para mantener la orden pasiva.

8.6. Valor económico en el test

La Tabla 8.4 y la Figura 8.5 muestran el desempeño en el test de las tres políticas con las intensidades de los modelos del ajuste corregido, todas con el mismo simulador, la misma orden de 0,01 BTC y el mismo límite de inventario. El precio medio de BTC en el test fue de unos 78 000 USDT, de modo que cada orden vale unos 780 USDT.

Tabla 8.4: PnL de market making en el test (17 días), bruto de comisiones; ajuste corregido. HJB con curva de distancia interpolada; GLFT con exponencial local. PnL por ejecución con IC95 por días.

Política	Intensidad	Ejec./día	PnL/día (USDT)	PnL por ejec. (bps)	Días > 0
Miope	E3 tesis	4 222	−443	−1,34 [−1,48; −1,19]	0/17
	AS, Hawkes, GLM con $f(\delta)$	3 806	−385	−1,29 [−1,45; −1,14]	0/17
	AS base y E3 base ($\delta = 2$)	1 173	−121	−1,32 [−1,84; −0,78]	4/17
	δ fijo 0,5 bps	6 872	−720	−1,34 [−1,42; −1,24]	0/17
HJB	E3 tesis	2 451	−253	−1,32 [−1,42; −1,20]	0/17
	E3 base	1 677	−175	−1,34 [−1,51; −1,15]	0/17
	GLM lineal	2 549	−262	−1,32 [−1,40; −1,22]	0/17
	Hawkes 2 esc. + S	3 543	−355	−1,28 [−1,35; −1,18]	0/17
	AS + h + f	3 982	−398	−1,28 [−1,35; −1,18]	0/17
	AS base	2 218	−219	−1,26 [−1,37; −1,14]	0/17
GLFT	E3 tesis	3 008	−289	−1,23 [−1,32; −1,11]	0/17
	Hawkes 2 esc. + S	2 321	−228	−1,25 [−1,36; −1,12]	0/17
	AS base	2 223	−218	−1,25 [−1,35; −1,13]	0/17

- **Las diferencias por ejecución entre combinaciones no son concluyentes.** Todas pierden entre −1,22 y −1,34 bps antes de comisiones, y las diferencias pareadas entre E3 tesis y cada referencia, en las tres políticas, tienen intervalos que incluyen el cero.
- **E3 cambia la política, no el resultado por ejecución.** Con la HJB, E3 tesis opera entre un 31 y un 38 % menos que AS y Hawkes con la misma forma de curva (2 451 frente a 3 543–3 982 ejecuciones por día) y pierde menos por día

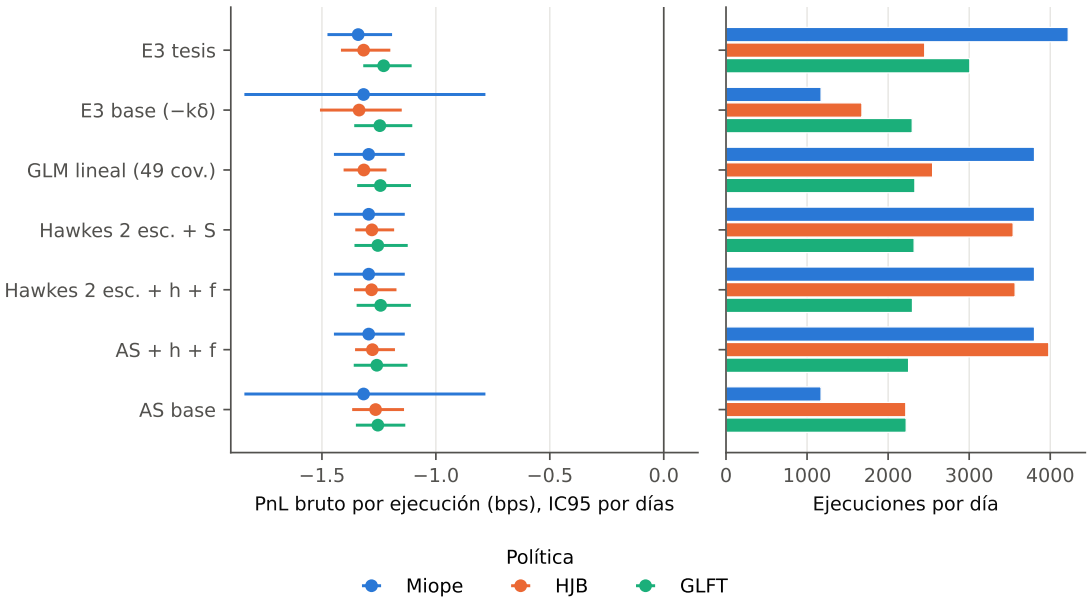


Figura 8.5: PnL bruto por ejecución (izquierda, IC95 por días) y ejecuciones por día (derecha) en el test, por intensidad y política; ajuste corregido, HJB con curva interpolada.

(−253 frente a −355 a −398 USDT); frente a AS base, con forma exponencial, opera un 10 % más. La pérdida por ejecución es similar en todos los casos.

- **La curva interpolada cambia las cotizaciones, no la pérdida por ejecución.** Frente a la HJB con exponencial local, aumenta las ejecuciones entre 723 y 1 735 por día según el modelo, con diferencias en el PnL por ejecución de −0,04 a +0,02 bps, todas con intervalos que incluyen el cero.
- **La regla miope colapsa a distancias fijas.** Como solo usa la forma de λ en δ, los modelos con curva $f(\delta)$ fija eligen siempre 1 bps y los de forma exponencial siempre 2 bps; solo E3 tesis varía la distancia con el estado.
- **Las comisiones agravan el resultado.** Con la comisión maker estándar de un participante minorista (7,5–10 bps por ejecución), todas las combinaciones pierden entre 9 y 11 bps por ejecución.

8.7. Simulación del 21 de septiembre al 26 de octubre

Con los mismos modelos y políticas, sin ningún reajuste, se evaluaron los 36 días posteriores al test. Antes de abrir el periodo se comprobó que el código reproduce exactamente un día del test (diferencia nula en predicción, ejecuciones y PnL).

Tabla 8.5: Simulación (21 sep.–26 oct., 36 días; modelos congelados). Parte de la mejora sobre AS base, ventaja de E3 tesis por segundo [IC95 por días], días ganados y AUC (ask / bid).

	Parte de la mejora		E3 tesis − modelo			
Modelo	ask	bid	ask	bid	Días	AUC
E3 tesis	100 %	100 %	–	–	–	0,848 / 0,842
E3-fkX (44 cov.)	100,2 %	99,3 %	−0,003 [−0,010; 0,005]	+0,008 [0,003; 0,014]	16 / 28	0,848 / 0,842
E3 base	94,5 %	94,2 %	+0,065 [0,047; 0,085]	+0,074 [0,058; 0,092]	33 / 36	0,847 / 0,842
GLM lineal (49 cov.)	90,8 %	90,0 %	+0,107 [0,071; 0,146]	+0,129 [0,077; 0,177]	32 / 35	0,840 / 0,836
Hawkes 2 esc. + S	70,2 %	70,7 %	+0,347 [0,295; 0,406]	+0,376 [0,321; 0,441]	36 / 36	0,785 / 0,783
Hawkes 2 esc. + h + f	58,8 %	62,2 %	+0,479 [0,389; 0,584]	+0,486 [0,403; 0,582]	36 / 36	0,764 / 0,765
Hawkes 1 esc. + S	43,6 %	41,9 %	+0,657 [0,551; 0,770]	+0,747 [0,613; 0,892]	36 / 36	0,746 / 0,743
AS + S	41,9 %	39,9 %	+0,676 [0,565; 0,795]	+0,773 [0,631; 0,927]	36 / 36	0,743 / 0,740
Hawkes 1 esc. + h + f	15,9 %	16,1 %	+0,979 [0,793; 1,205]	+1,079 [0,852; 1,321]	36 / 36	0,654 / 0,654
AS + h + f	14,1 %	13,9 %	+0,999 [0,809; 1,230]	+1,107 [0,873; 1,360]	36 / 36	0,642 / 0,642
AS base	0 %	0 %	+1,164 [0,946; 1,419]	+1,286 [1,016; 1,575]	36 / 36	0,500 / 0,500

Predicción. El orden de los modelos se mantiene y el AUC de E3 tesis sube a 0,85, sin degradación semana a semana (0,81 a 0,87 en las cinco semanas; 0,83 a 0,87 en las tres semanas desde el 5 de octubre). E3 tesis supera a todas las referencias con intervalos que excluyen el cero, salvo a E3-fkX en el lado ask, como en el test. De los cuatro criterios del test, escalados a 36 días, se cumplen los tres primeros (jerarquía, consistencia y AUC). El de calibración tras barridos no se cumple: la brecha es +0,11 tras barridos vendedores y +0,22 tras compradores, frente al límite de ±0,15.

Valor económico. Los resultados repiten los del test (Tabla 8.6). Ninguna combinación de modelo y política es rentable. Con la HJB, las diferencias por ejecución entre E3 tesis y las referencias no son significativas. Con la regla miope, E3 tesis pierde 0,08 bps más por ejecución que los modelos que cotizan siempre a 1 bps (IC95 [−0,128; −0,028]), porque se acerca al precio medio en los momentos de mayor intensidad predicha. Las tablas de la HJB cubren el periodo: en promedio, el 0,3–0,5 % de los segundos cae fuera de sus rangos.

8.8. Origen de la pérdida

Cada ejecución puede descomponerse en dos partes: la distancia capturada respecto del precio medio en el momento de la decisión y el movimiento posterior del precio medio. Su suma es el *markout* (5.3). La Tabla 8.7 la presenta para las ejecuciones del test y de la simulación.

En los dos periodos y en todas las combinaciones se repite la misma regularidad. Lo que se captura de más al cotizar más lejos (de +0,9 a +2,0 bps) se pierde en un

Tabla 8.6: PnL en la simulación (36 días), bruto de comisiones; modelos congelados, HJB con curva interpolada. PnL por ejecución con IC95 por días.

Política	Intensidad	Ejec./día	PnL/día (USDT)	PnL por ejec. (bps)	Días > 0
Miope	E3 tesis	4 406	−449	−1,22 [−1,31; −1,14]	0/36
	AS, Hawkes, GLM con $f(\delta)$	3 869	−369	−1,14 [−1,22; −1,07]	0/36
	AS base ($\delta = 2$)	975	−98	−1,20 [−1,52; −0,89]	9/36
HJB	E3 tesis	2 375	−249	−1,26 [−1,34; −1,18]	0/36
	GLM lineal	2 398	−250	−1,25 [−1,32; −1,18]	0/36
	Hawkes 2 esc. + S	3 612	−369	−1,23 [−1,28; −1,18]	0/36
	AS base	2 115	−212	−1,20 [−1,27; −1,13]	1/36
GLFT	E3 tesis	3 065	−309	−1,21 [−1,27; −1,15]	0/36
	AS base	2 120	−213	−1,20 [−1,27; −1,13]	1/36

Tabla 8.7: Descomposición de la pérdida por ejecución (bps; media por ejecución): distancia capturada, movimiento posterior del precio medio y *markout* a 10 s. Modelos congelados.

Periodo	Combinación	Capturada	Mov. 1 s	Mov. 10 s	*Markout* 10 s	% > 0
Test	E3 tesis, miope	+0,92	−1,78	−2,15	−1,24	23
	E3 tesis, HJB	+1,08	−2,08	−2,36	−1,28	27
	Hawkes 2 esc. + S, HJB	+1,01	−1,96	−2,28	−1,27	26
	AS base, HJB	+1,46	−2,43	−2,75	−1,29	29
	AS base, miope ($\delta = 2$)	+2,00	−3,04	−3,31	−1,31	32
Simulación	E3 tesis, HJB	+1,04	−1,93	−2,28	−1,24	27
	AS base, HJB	+1,46	−2,30	−2,64	−1,18	29
	AS base, miope ($\delta = 2$)	+2,00	−2,92	−3,21	−1,21	32

movimiento posterior mayor (de −2,1 a −3,3 bps), y el *markout* queda entre −1,16 y −1,31 bps. Una cotización alejada solo se ejecuta cuando un barrido grande la atraviesa, y tras ese barrido el precio sigue en la misma dirección. Entre el 80 y el 90 % del movimiento a 10 s ocurre en el primer segundo, y solo entre el 23 y el 32 % de las ejecuciones resulta ganador. En BTC/USDT el spread es de un tick el 99,96 % del tiempo, así que el margen por cotizar procede únicamente de la distancia elegida, y esa distancia queda compensada por el movimiento posterior.

La pérdida tampoco depende de la intensidad que predice el modelo. Ordenando las ejecuciones de E3 tesis con la HJB por su intensidad predicha a 2 bps, la distancia capturada sube del decil más bajo al más alto (de 0,4 a 2,2 bps en el test), pero el *markout* se mantiene entre −1,0 y −1,4 bps en el test y entre −1,15 y −1,30 bps en la simulación. Con la regla miope, el decil de mayor intensidad es el que más pierde (−1,39 bps en el test y −1,25 bps en la simulación).

En las configuraciones probadas en el entrenamiento, el resultado fue robusto al simulador, al modelo de cola y a la latencia. La regla de ejecución usada aquí coincide con simuladores que modelan la cola explícitamente: con hftbacktest, a 0,01–0,06 bps por ejecución; con NautilusTrader, entre −1,22 y −1,27 bps frente a −1,26. Reducir la latencia simulada de 100 ms a 10 μs deja la pérdida entre −1,21 y −1,28 bps. Estas comprobaciones, con políticas simétricas cerca del mejor precio, no cubren el test ni otras políticas, y los datos de 100 ms no permiten simular cancelaciones en microsegundos. Otras pruebas exploratorias de la parte económica, ninguna rentable después de comisiones, se resumen en el Apéndice C.

8.9. Avance frente a los objetivos

La Tabla 8.8 resume, para cada objetivo específico del anteproyecto, la evidencia que lo atiende y la sección donde se presenta.

Tabla 8.8: Cumplimiento de los objetivos específicos.

OE	Evidencia
OE1	E1 estimado por lado; su forma exponencial queda mal calibrada por distancia y su nivel constante deja el AUC en 0,5. En la política, la distancia base depende de k y no de A (Secciones 8.1 y 8.5).
OE2	Intensidad (5.8) con 49 covariables, h horaria, curva monótona y modulación por estado; ablaciones y calibración tras barridos (Sección 8.1).
OE3	GBM y *Random Forest* comparados con la misma información: conclusiones iguales, GBM más eficiente (Sección 8.1).
OE4	HJB derivada y resuelta numéricamente con intensidades dependientes del estado, verificada contra soluciones conocidas y aplicada en el test (Sección 8.5).
OE5	Comparación económica en el test frente a AS y Hawkes, con PnL, inventario y selección adversa; robustez entre ventanas, simuladores, colas y latencias (Secciones 8.2 y 8.6).

Capítulo 9

Discusión

9.1. Las dos preguntas

¿Cuánto mejora E3 la estimación? De forma sustancial y estable. Frente a Avellaneda–Stoikov, E3 gana alrededor de 1,3 unidades de log-verosimilitud por segundo en el test, todos los días y en ambos lados, y pasa de un AUC de 0,5 a uno de 0,81. La pregunta más exigente es cuánto de esa mejora alcanzan las referencias cuando reciben la misma información. El Hawkes de dos escalas con señales llega al 74 % y el modelo lineal con las 49 covariables al 90 %; ninguno alcanza a E3 en ningún tramo del *walk-forward* ni del test. La descomposición es informativa:

- la información del estado del libro y del flujo reciente explica la mayor parte de la ganancia;
- la memoria endógena aporta cuando se modela a la escala correcta: el Hawkes de una escala, con memoria de milisegundos, apenas supera a la referencia;
- la no linealidad de g aporta el último 10 % y, entre los modelos evaluados, es la que mejor discrimina y mejor calibra el comportamiento tras barridos; esto no excluye que otra especificación lineal pudiera lograrlo.

En la simulación posterior, de 36 días y sin reajustes, el orden de los modelos y la magnitud de las ventajas se mantienen, con un AUC de 0,85. Esta descomposición responde a P1 y a OE2–OE3: la forma semiparamétrica conserva la estructura interpretable de Avellaneda–Stoikov (nivel por estado, periodicidad, curva de distancia) y mejora cada uno de sus supuestos restrictivos.

¿Qué valor económico produjo? Ninguno positivo bajo las políticas evaluadas. Con la regla miope, con la HJB numérica o con su aproximación cerrada, todas las intensidades pierden aproximadamente entre 1,1 y 1,3 bps por ejecución antes de comisiones, en el test y en la simulación. En el test las diferencias entre modelos no son significativas; en la simulación, con la regla miope, E3 pierde 0,08 bps más por ejecución que los modelos que cotizan a distancia fija, porque se acerca al precio medio cuando predice más actividad. Lo que sí cambia con E3 es la política: con la HJB opera entre un 31 y un 38 % menos que AS y Hawkes con la misma forma

de curva, y pierde menos por día. Esto responde a P3: la estimación *data-driven* cambia la política HJB con coeficientes congelados, sobre todo a través del cociente de intensidades entre lados. Y responde a P2: ese cambio no produce un PnL neto positivo ni una pérdida por ejecución menor que la de Avellaneda–Stoikov y Hawkes.

9.2. Por qué la mejora predictiva no se traduce en rentabilidad

La explicación que sigue es una interpretación acotada a los tres modelos y a la regla de ejecución evaluados. Los tres (Avellaneda–Stoikov, Hawkes y E3) estiman lo mismo: cuándo y a qué distancia llegarán agresores. Ninguno se estimó para predecir hacia dónde se moverá el precio después de una ejecución. Con la misma regla de ejecución, las políticas derivadas de cada modelo difieren en las distancias de cotización y en la frecuencia de participación (el tamaño de cada orden está fijado en 0,01 BTC), pero las ejecuciones que obtienen tienen un *markout* a 10 s muy parecido, de −1,16 a −1,31 bps. La descomposición de la Sección 8.8 muestra el mecanismo: cotizar más lejos captura más margen, pero solo se es ejecutado cuando un barrido atraviesa esa distancia, y el movimiento posterior compensa el margen adicional. Por eso una mejor predicción de la intensidad cambia el volumen operado y el momento de las cotizaciones, pero no se tradujo en una pérdida por ejecución distinta.

Esta lectura es coherente con la teoría y con la evidencia reciente. En el marco de Glosten and Milgrom (1985), el spread remunera la selección adversa; en BTC/USDT el spread es casi siempre de un tick, de modo que esa remuneración es mínima. Albers et al. (2025) documentan, con experimentos en vivo en Binance, una relación negativa entre la probabilidad de ejecución y el retorno posterior, y DeLise (2024) describe la deriva negativa del precio tras la ejecución de una orden límite. Que la precisión estadística no implique valor económico es un resultado conocido en la evaluación de pronósticos (Leitch and Tanner, 1991).

Hay condiciones que podrían cambiar el resultado y que este trabajo no evaluó, o evaluó solo en parte; no se afirma que sean necesarias ni suficientes:

- una devolución por proveer liquidez del orden de la pérdida por ejecución medida;
- información sobre la dirección posterior a la ejecución, que no se encontró con las covariables disponibles;
- cancelar órdenes en microsegundos antes de ser ejecutado: los datos de 100 ms no permiten simular esas carreras, que según la literatura se libran en mi-

crosegundos y concentran pocas firmas (Budish et al., 2015; Aquilina et al., 2022);

- un mercado con spread más ancho o con otro diseño, como subastas por lotes.

Este trabajo describe lo observado para un participante sin devoluciones, con la regla de ejecución y los datos utilizados.

9.3. Limitaciones

- **Exposición previa del test.** El test del 4 al 20 de septiembre no es ciego en sentido estricto para P1: la especificación original de E3 ya se había evaluado en esas fechas dentro del primer test ciego, y una política de pausa se ejecutó en él antes de una orden de espera, sin que sus resultados se consultaran. Lo que confirma el test son las especificaciones nuevas, que nunca se evaluaron allí.
- **Periodo de la simulación.** Hasta el 6 de octubre, parte del periodo de simulación se usó en la fase exploratoria para evaluar una versión anterior del modelo. Ninguna decisión de los modelos finales se tomó con esos datos.
- **Asimetrías de estimación.** Los Hawkes se ajustaron con un tercio de los días por costo computacional, aunque sus capas de nivel, forma y señales usan todos. El ajuste de E3 usa un número fijo de ciclos de *backfitting* y no verifica formalmente la convergencia del optimizador de la curva. Además, el gradiente analítico de $m(X)$ no incorporaba el recorte de $b^\top z$ a ± 5, que se activa en unos 30 de 5,8 millones de segundos del entrenamiento. Una verificación posterior corrigió el gradiente y comprobó la convergencia del último paso de la curva, con g y h fijos (no la convergencia conjunta de todo el *backfitting*): la curva solo cambia en 15–20 bps (hasta 0,33 en logaritmo), con una ganancia de verosimilitud de unas 6×10^{-6} unidades por segundo. La verosimilitud de entrenamiento aumenta en cada ciclo, pero el efecto de una convergencia incompleta sobre el desempeño fuera de muestra no se cuantificó y queda como incertidumbre.
- **Alcance frente a ejecución.** La respuesta mide el alcance de una cotización, no su ejecución con prioridad en la cola; la evaluación económica usa una regla conservadora validada con colas explícitas solo en agregados.
- **Política aproximada.** La HJB se aplica con coeficientes congelados, con la curva de distancia interpolada entre nueve nodos y extendida fuera de ellos, y mediante tablas numéricas; no incorpora la dinámica de X_t como estado. GLFT usa además una aproximación exponencial local.

- **Calibración restante.** La calibración tras barridos no es estable: la celda "comprador con tendencia bajista" no se corrigió en el *walk-forward*, y en la simulación la brecha tras barridos compradores fue de +0,22, fuera del límite de ±0,15; la verosimilitud es compuesta porque los conteos están anidados en δ, y los días no son independientes.
- **Un solo mercado y un participante lento.** Los resultados se refieren a BTC/USDT spot en Binance, el libro más competido, observado con 100 ms de resolución. La evaluación económica supone que la orden queda activa al inicio de cada segundo, sin latencia de envío; no reproduce a un participante con los 130 ms de latencia de red medidos en la captura.

Capítulo 10

Conclusiones y trabajo futuro

Este trabajo propuso y evaluó una intensidad semiparamétrica de llegada de órdenes agresivas para market making en BTC/USDT, $\lambda_i(t, \delta \mid X_t) = \exp\{g_i(X_t) + h_i(t) + m_i(X_t) f_i(\delta)\}$, y la comparó con Avellaneda–Stoikov y con un Hawkes bivariado reforzados con los mismos hallazgos. Las conclusiones son:

1. **La intensidad semiparamétrica predice mejor.** Supera a las referencias en las cinco ventanas del *walk-forward*, en el test y en una simulación posterior de 36 días sin reajustes, en ambos lados del libro, con un AUC de 0,81–0,85. Los intervalos de confianza por días excluyen el cero frente a todas las referencias, salvo frente a E3-fkX en el lado ask, donde la diferencia no es significativa en el test ni en la simulación. Se cumplieron todos los criterios preregistrados del *walk-forward* y del test; en la simulación falló el de calibración tras barridos.

2. **La ganancia proviene sobre todo del estado del mercado.** Un modelo lineal con las mismas covariables recupera el 90 %; la no linealidad añade el resto y, frente a las referencias evaluadas, mejoró la discriminación y la calibración tras barridos. El Hawkes recupera el 60–74 % solo cuando tiene dos escalas de memoria.

3. **La forma en la distancia importa.** Una curva monótona modulada por el estado corrige la mala calibración de $e^{-k\delta}$, y las covariables de barrido corrigen la subestimación del rebote en tres de cuatro situaciones.

4. **La estimación *data-driven* cambia la política de cotización.** La HJB resuelta numéricamente y aplicada con coeficientes congelados, con la curva de distancia interpolada, se sesga según el cociente de intensidades entre lados y según la pendiente de la curva; con E3 opera entre un 31 y un 38 % menos que AS y Hawkes con la misma forma de curva. En la aproximación cerrada GLFT, el nivel de la intensidad solo entra en el término de inventario, porque la distancia base $\gamma^{-1} \log(1 + \gamma/k_i)$ no depende de A_i.

5. **Ninguna política es rentable.** Con cualquier intensidad y cualquiera de las tres políticas, el market making pasivo pierde aproximadamente entre 1,1 y

1,3 bps por ejecución antes de comisiones, en el test y en la simulación. Lo que se captura al cotizar más lejos queda compensado por un movimiento posterior mayor del precio, la mayor parte en el primer segundo: es selección adversa en un mercado con spread de un tick. Las diferencias entre modelos son pequeñas; la única significativa es que, con la regla miope, E3 pierde 0,08 bps más por ejecución en la simulación.

La contribución del trabajo es, por tanto, predictiva, y su resultado económico es negativo y explicado. Ambos se sustentan con el mismo protocolo: datos propios auditados, especificaciones congeladas antes de evaluar y criterios fijados de antemano. El periodo de test había sido consultado antes con una versión anterior del modelo, y congelar una versión nueva no recupera su independencia.

Trabajo futuro.

- Modelar conjuntamente la probabilidad de ejecución y el *markout* posterior, que es la cantidad económicamente relevante. En la fase exploratoria, las covariables disponibles explicaron menos del 3 % de la variación del *markout* por ejecución, por lo que su valor con datos de 100 ms es dudoso.
- Repetir la comparación en mercados con spread más ancho o con comisión maker nula o negativa, y en otras plataformas como Coinbase BTC-USD, donde la ventaja predictiva podría monetizarse.
- Incorporar X_t como variable de estado en la HJB, en lugar de coeficientes congelados.
- Medir la latencia propia en operación real o capturar desde la región del motor de Binance, para estudiar las carreras de cancelación que los datos de 100 ms no permiten simular.

Apéndice A

Covariables y disponibilidad del código

A.1. Covariables de E3

Las 49 covariables se calculan con información disponible antes de cada decisión (Tabla A.1). Las ventanas `past_*` excluyen el intervalo actual. Las covariables de barrido usan transacciones estrictamente anteriores y superan la prueba automática de truncamiento.

Tabla A.1: Covariables de $g(X_t)$ por grupo.

Grupo	n	Variables
Libro	15	spread; desequilibrio en los niveles 1, 5 y 20 y ponderado; prima del microprecio; profundidad de compra y venta en 5 y 20 niveles; pendiente del libro por lado; entropía de la profundidad por lado; antigüedad del libro
OFI	4	OFI ponderado en 1, 5 y 20 niveles; OFI de 5 niveles
Volatilidad	5	volatilidad realizada a 1, 5, 10 y 60 s; variación del precio medio en 100 ms
Flujo	20	número y volumen de compras y ventas agresoras, y volumen firmado, en ventanas de 1, 5, 30 y 60 s
Barridos	5	recorrido firmado, volumen y tiempo desde el último barrido (evento agresor que recorre al menos 0,5 bps, en los últimos 60 s); spread máximo del último segundo; variación del precio medio en el último segundo

La modulación $m(X)$ usa cuatro covariables estandarizadas: volatilidad realizada a 10 s, $\log(1 + \text{transacciones en 5 s})$, logaritmo de la profundidad propia en cinco niveles y desequilibrio en cinco niveles. Las siete señales S de las referencias son las cinco de barrido y las variaciones del precio medio en 15 min y 1 h.

A.2. Disponibilidad y verificación

El código, los protocolos de cada etapa y los modelos finales están en el repositorio del proyecto:

https://github.com/sannti09/market-making-semiparametrico

La versión del código que corresponde a este documento es el *commit* `9c57cd2`; el documento compilado se añadió en el *commit* siguiente. El repositorio es público: el código se distribuye con licencia MIT y este documento con licencia Creative Commons Atribución 4.0 (CC BY 4.0). Cada protocolo se escribió y fechó antes de correr la etapa correspondiente, y el código comprueba al ejecutarse que el protocolo no cambió. Los modelos finales se guardaron antes de leer el test. El repositorio incluye además el catálogo de los archivos de datos, que permite verificar que cualquier réplica usa exactamente los mismos datos.

Apéndice B

Desarrollo y evaluación de la especificación original

B.1. Fase de desarrollo

La Tabla B.1 compara la especificación original de E3 con AS y con el Hawkes de una escala en la calibración interna (13–16 de julio), con hiperparámetros elegidos en ese mismo bloque.

Tabla B.1: Fase de desarrollo. Log-verosimilitud en calibración interna (4 días, 345 600 intervalos por lado) y AUC medio ($\delta = 2$ bps). Mayor es mejor.

Modelo	ℓ ask	ℓ bid	AUC ask	AUC bid
E1: $Ae^{-k\delta}$	−903 215	−803 621	0,500	0,500
E1 $+h$(hora)	−789 821	−758 297	0,695	0,676
E2: Hawkes de una escala	−886 725	−794 714	0,643	0,653
E3: GBM	**−418 255**	**−468 377**	**0,840**	**0,843**
E3: *Random Forest*	−423 078	−467 767	0,840	0,844

B.2. Validación y tests ciegos

Antes de reforzar los modelos, la especificación original de E3 se evaluó en tres bloques que no se usaron para elegirla. La Tabla B.2 resume los resultados.

Tabla B.2: E3 original frente a E1 en bloques posteriores al desarrollo: días en que gana E3, mejora por intervalo [IC95 por días] y AUC.

Bloque	Días	Mejora ask	Mejora bid	AUC ask / bid
Validación (17–23 jul.)	7/7	0,85 [0,72; 1,03]	0,92 [0,69; 1,26]	0,806 / 0,802
Ciego 1 (26 ago.–15 sep.)	21/21	1,30 [0,96; 1,69]	1,29 [0,87; 1,79]	0,810 / 0,798
Ciego 2 (16 sep.–6 oct.)	21/21	1,13 [0,79; 1,51]	1,39 [0,95; 1,88]	0,831 / 0,828

E3 superó a E1 y a E1 con efecto horario en todos los días de los tres bloques y en ambos lados. Los veredictos preregistrados fueron: validación cumplida; ciego 1

no cumplido; ciego 2 cumplido. En el ciego 1 fallaron dos criterios. El AUC del lado bid quedó en 0,798, por debajo del umbral de 0,80. El cociente entre la mejora del bloque y la de referencia quedó en 0,23–0,25, porque la referencia elegida (18–21 de agosto) correspondía a días extremos; fue un error de diseño del protocolo, que se reporta sin cambios.

Un GLM lineal con las mismas 44 covariables recuperaba el 88–93 % de la mejora de E3, pero con un AUC de 0,78–0,79, por debajo del umbral; E3 le ganó en AUC todos los días.

Apéndice C

Pruebas exploratorias de la parte económica

Estas pruebas se hicieron en el entrenamiento, o en bloques ya vistos, para buscar una vía rentable o entender la pérdida. Ninguna fue rentable después de comisiones; algunas variantes agresivas tuvieron un resultado bruto positivo. Se resumen para que el lector conozca qué se intentó.

Por qué algunos *backtests* intermedios parecieron mucho mejores. Un simulador que daba por ejecutadas como pasivas cotizaciones que en realidad habrían cruzado el libro reducía artificialmente la pérdida de $-1{,}26$ a $-0{,}2$ bps por ejecución; la validación con cola explícita lo detectó y ese resultado se retiró. Otras métricas excluían las operaciones perdedoras (por ejemplo, contar solo ciclos cerrados con un precio mínimo de salida) o comparaban con mantener la posición, lo que mide la dirección del inventario y no la provisión de liquidez.

Pausa defensiva. Retirar las cotizaciones cuando un modelo de saltos anticipa alta probabilidad de un movimiento brusco reduce la pérdida entre 0,03 y 0,09 bps por ejecución, con intervalos que excluyen el cero, pero la mejor combinación queda en $-1{,}03$ bps y ningún día es positivo. Saber *cuándo* habrá un salto es posible (AUC 0,81–0,91); saber *hacia dónde* acierta el 58–60 % de las veces, frente al 54 % que se obtiene prediciendo siempre la dirección más frecuente.

Spreads anchos. Un spread de al menos 1 bps aparece en promedio 1,4 s al día. El 85–96 % de esos episodios los abre un barrido, tras el cual el precio sigue en la dirección del barrido. Incluso suponiendo una ejecución asegurada en esos instantes, el resultado a 10 s es de $-3{,}9$ a $-5{,}9$ bps.

Operar como agresor. Una señal de dirección a 10 s construida con las covariables de E3 captura entre 0,65 y 0,8 bps por orden antes de comisiones; seguir la dirección de un barrido tras un spread ancho no supera de forma robusta el umbral

de comisión. Ninguna variante probada cubre la comisión de ida y vuelta de un participante minorista.

Información externa. En las pruebas realizadas, los perpetuos de otras plataformas mejoraron la predicción de dirección frente a un modelo lineal simple, pero no frente a un GBM con las covariables propias del libro; otras criptomonedas, índices bursátiles y opciones no mostraron una anticipación útil a los horizontes evaluados.

Bibliografía

Jakob Albers, Mihai Cucuringu, Sam Howison, and Alexander Y. Shestopaloff. The market maker's dilemma: Navigating the fill probability vs. post-fill returns trade-off. arXiv preprint arXiv:2502.18625, 2025.

Matteo Aquilina, Eric Budish, and Peter O'Neill. Quantifying the high-frequency trading "arms race". *Quarterly Journal of Economics*, 137(1):493–564, 2022. doi: 10.1093/qje/qjab032.

Marco Avellaneda and Sasha Stoikov. High-frequency trading in a limit order book. *Quantitative Finance*, 8(3):217–224, 2008. doi: 10.1080/14697680701381228.

Emmanuel Bacry, Iacopo Mastromatteo, and Jean-François Muzy. Hawkes processes in finance. *Market Microstructure and Liquidity*, 1(1):1550005, 2015. doi: 10.1142/S2382626615500057.

Emilio Barucci, Giancarlo Giuffra Moncayo, and Daniele Marazzina. Cryptocurrencies and stablecoins: a high-frequency analysis. *Digital Finance*, 4(2–3):217–239, 2022. doi: 10.1007/s42521-022-00055-9.

Binance. Binance spot api documentation: Websocket market streams. https://github.com/binance/binance-spot-api-docs/blob/master/web-socket-streams.md, 2026. Documentación oficial en línea; consultada el 29 de octubre de 2026.

Clive G. Bowsher. Modelling security market events in continuous time: intensity based, multivariate point process models. *Journal of Econometrics*, 141(2):876–912, 2007. doi: 10.1016/j.jeconom.2006.11.007.

Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001. doi: 10.1023/A:1010933404324.

Eric Budish, Peter Cramton, and John Shim. The high-frequency trading arms race: frequent batch auctions as a market design response. *Quarterly Journal of Economics*, 130(4):1547–1621, 2015. doi: 10.1093/qje/qjv027.

Álvaro Cartea and Yixuan Wang. Market making with alpha signals. *International Journal of Theoretical and Applied Finance*, 23(3):2050016, 2020. doi: 10.1142/S0219024920500168.

Álvaro Cartea, Sebastian Jaimungal, and José Peñalva. *Algorithmic and High-Frequency Trading*. Cambridge University Press, Cambridge, 2015. doi: 10.1017/CBO9781316466100.

Rama Cont, Arseniy Kukanov, and Sasha Stoikov. The price impact of order book events. *Journal of Financial Econometrics*, 12(1):47–88, 2014. doi: 10.1093/jjfinec/nbt003.

Timothy DeLise. The negative drift of a limit order fill. arXiv preprint arXiv:2407.16527, 2024.

Bradley Efron and Robert J. Tibshirani. *An Introduction to the Bootstrap*. Chapman and Hall, New York, 1993.

Timothée Fabre and Ioane Muni Toke. Neural Hawkes: Non-parametric estimation in high dimension and causality analysis in cryptocurrency markets. *Quantitative Finance*, 25(5):671–698, 2025. doi: 10.1080/14697688.2025.2477673.

Tom Fawcett. An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8):861–874, 2006. doi: 10.1016/j.patrec.2005.10.010.

Jerome H. Friedman. Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5):1189–1232, 2001. doi: 10.1214/aos/1013203451.

Lawrence R. Glosten and Paul R. Milgrom. Bid, ask and transaction prices in a specialist market with heterogeneously informed traders. *Journal of Financial Economics*, 14(1):71–100, 1985. doi: 10.1016/0304-405X(85)90044-3.

Tilmann Gneiting. Making and evaluating point forecasts. *Journal of the American Statistical Association*, 106(494):746–762, 2011. doi: 10.1198/jasa.2011.r10138.

Tilmann Gneiting and Adrian E. Raftery. Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477):359–378, 2007. doi: 10.1198/016214506000001437.

Léo Grinsztajn, Edouard Oyallon, and Gaël Varoquaux. Why do tree-based models still outperform deep learning on typical tabular data. *Advances in Neural Information Processing Systems*, 35, 2022. URL https://proceedings.neurips.cc/paper_files/paper/2022/hash/0378c7692da36807bdec87ab043cdadc-Abstract-Datasets_and_Benchmarks.html.

Olivier Guéant. Optimal market making. *Applied Mathematical Finance*, 24(2): 112–154, 2017. doi: 10.1080/1350486X.2017.1342552.

Olivier Guéant, Charles-Albert Lehalle, and Joaquin Fernandez-Tapia. Dealing with the inventory risk: a solution to the market making problem. *Mathematics and Financial Economics*, 7(4):477–507, 2013. doi: 10.1007/s11579-012-0087-0.

Alan G. Hawkes. Spectra of some self-exciting and mutually exciting point processes. *Biometrika*, 58(1):83–90, 1971. doi: 10.1093/biomet/58.1.83.

Luca Lalor and Anatoliy Swishchuk. Market simulation under adverse selection. arXiv preprint arXiv:2409.12721, 2024.

Gordon Leitch and J. Ernest Tanner. Economic forecast evaluation: profits versus the conventional error measures. *American Economic Review*, 81(3):580–590, 1991.

Xiaofei Lu and Frédéric Abergel. High-dimensional hawkes processes for limit order books: modelling, empirical analysis and numerical calibration. *Quantitative Finance*, 18(2):249–264, 2018. doi: 10.1080/14697688.2017.1403142.

Maxime Morariu-Patrichi and Mikko S. Pakkanen. State-dependent hawkes processes and their application to limit order book modelling. *Quantitative Finance*, 22 (3):563–583, 2022. doi: 10.1080/14697688.2021.1983199.

Luca Mucciante and Alessio Sancetta. Estimation of an order book dependent hawkes process for large datasets. *Journal of Financial Econometrics*, 22(4):1098–1129, 2024. doi: 10.1093/jjfinec/nbad021.

Maureen O'Hara. *Market Microstructure Theory*. Blackwell, Cambridge, MA, 1995.

Tohru Ozaki. Maximum likelihood estimation of Hawkes' self-exciting point processes. *Annals of the Institute of Statistical Mathematics*, 31(1):145–155, 1979. doi: 10.1007/BF02480272.

Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12(85):2825–2830, 2011. URL https://www.jmlr.org/papers/v12/pedregosa11a.html.

Marcello Rambaldi, Emmanuel Bacry, and Fabrizio Lillo. The role of volume in order book dynamics: a multivariate hawkes process analysis. *Quantitative Finance*, 17 (7):999–1020, 2017. doi: 10.1080/14697688.2016.1260759.

Peter M. Robinson. Root-N-consistent semiparametric regression. *Econometrica*, 56(4):931–954, 1988. doi: 10.2307/1912705.

Alejandro Veen and Frederic P. Schoenberg. Estimation of space–time branching process models in seismology using an EM-type algorithm. *Journal of the American Statistical Association*, 103(482):614–624, 2008. doi: 10.1198/016214508000000148.